涉密论文 □　公开论文 □

浙 江 大 學

本科生毕业论文



题目　　时序预测问题因子挖掘的模拟方法

姓名与学号　　郭景行 3220102983

指导教师　　胡贤良

年级与专业　　2022级统计学

所在学院　　数学科学学院

递交日期　　2026 年 5 月 27 日

浙江大学本科生毕业论文（设计）承诺书

1. 本人郑重地承诺所呈交的毕业论文（设计），是在指导教师的指导下严格按照学校和学院有关规定完成的。

2. 本人在毕业论文（设计）中除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得**浙江大学**或其他教育机构的学位或证书而使用过的材料。

3. 与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

4. 本人承诺在毕业论文（设计）工作过程中没有伪造数据等行为。

5. 若在本毕业论文（设计）中有侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

6. 本人完全了解**浙江大学**有权保留并向有关部门或机构送交本论文（设计）的复印件和磁盘，允许本论文（设计）被查阅和借阅。本人授权**浙江大学**可以将本论文（设计）的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编本论文（设计）。

作者签名：　　导师签名：

签字日期：　　年　月　日　　签字日期　　年　月　日

致 谢

首先，衷心感谢我的导师胡贤良老师在论文选题与研究推进方面给予我的宽容与指导。

感谢我在敦和资管大家庭的 mentor 马嘉晨，在我从因子挖掘到预测框架构建的全过程中，给予了方法规范性上的系统指导与研究思路上的持续启迪。感谢敦和资管提供的数据与算力支持，使本文的实验设计与工程验证得以顺利开展。

感谢我的室友和好友陈万祺，使我更早接触并适应智能化编程工具。

感谢我的父母一直以来的默默支持。

感谢我的伯伯赵伟江，没有他的期许与帮助，我可能很难迈出第一步。

最后，感谢所有喜欢和帮助我的人。

摘 要

本文以股票收益预测为实验载体，研究时序预测问题中的因子挖掘模拟方法，重点考察如何在分钟频与日频混合输入条件下构建兼具可解释性、可复现性与工程可落地性的自动化因子发现框架。区别于直接使用端到端深度学习模型的路线，本文以遗传编程（Genetic Programming, GP）为核心。GP 是一种通过演化搜索自动生成数学表达式的方法，本文重点检验其生成的公式化因子在严格样本外条件下的有效性，并结合早期日频探索结果说明研究路径的演化过程。

方法上，本文构建了面向混合频率数据的类型受约束 GP 框架，设计分钟保持算子、分钟时序函数、日内聚合函数与日频层函数，以约束跨频率表达式的合法组合；以横截面平均 Rank IC 作为核心适应度，并结合 IC 阈值与相似度硬筛控制因子质量与冗余；在工程实现上采用 `numpy.memmap` 与分层并行机制，缓解高维分钟张量带来的存储与计算压力。实验以中证 500 历史成分股为股票池，训练标签采用中性化 5 日成交量加权平均价格（Volume Weighted Average Price, VWAP）收益，组合收益采用 1 日原始收益字段 `raw1d` 逐日单利记账，并在万三交易成本、5 日调仓与滚动更新因子集合条件下进行样本外评估。

实证结果表明，本文挖掘得到的有效 GP 因子在单因子层面具有正向 Rank IC、较好的分层单调性与正向的第 10 组和第 1 组收益差。在组合层面，滚动的前 15 个 GP 因子经横截面 z-score 标准化后等权合成，构造的 20 只股票持有组合在 2020-09-28 至 2025-12-31 的样本外区间内取得 103.95% 的累计收益、19.76% 的年化收益和 75.30% 的相对中证 500 超额收益，最大回撤为 -20.01%。进一步比较不同后续信号合成模型后发现，ElasticNet 能够提高组合净值，但其整体 Rank IC 弱于简单等权组合；XGBoost 与 GRU 则未稳定提升全截面排序能力。总体而言，混合频率 GP 因子本身包含可交易的样本外信息；在后续信号合成中，简单下游模型在信息转化稳健性上优于当前设定的复杂模型。

早期基于日频字段、且不含时序函数的 GP 也能通过与 GRU 结合生成具有一定效果的预测信号，但相邻版本之间波动较大。该现象说明，不同复杂度的因子结构与下游模型之间可能存在匹配关系：复杂时序因子更适合配合简单透明的信号合成方式，而简单因子则可能需要更强的时序模型进一步提炼信息。

关键词：遗传编程，混合频率数据，因子挖掘，分钟频建模，样本外回测

Abstract

This paper takes stock return prediction as the experimental vehicle to study factor mining simulation methods in time-series forecasting, focusing on how to construct an automated factor discovery framework that is interpretable, reproducible, and practically deployable under mixed minute-frequency and daily-frequency input conditions.

Instead of directly employing end-to-end deep learning models, this paper adopts Genetic Programming (GP) as the core technique. GP is a method that automatically generates mathematical expressions through evolutionary search. The paper focuses on validating the effectiveness of the resulting formulaic factors under strict out-of-sample conditions, and also references early exploratory results based on daily-frequency data to illustrate the evolution of the research path.

Methodologically, a type-constrained GP framework for mixed-frequency data is built. Minute-preserving operators, minute-wise time-series functions, intra-day aggregation functions, and daily-layer functions are designed to constrain the legal combination of cross-frequency expressions. The cross-sectional average Rank IC is used as the core fitness measure, combined with an IC threshold and similarity-based hard screening to control factor quality and redundancy. On the engineering side, `numpy.memmap` and a hierarchical parallelisation mechanism are employed to alleviate the storage and computational pressure caused by high-dimensional minute-frequency tensors. The experiments use the historical constituents of the CSI 500 index as the stock pool. The training label is the neutralised 5-day Volume Weighted Average Price (VWAP) return, while the portfolio return uses the 1-day raw return field `raw1d` with daily simple-interest accounting. Out-of-sample evaluation is conducted under conditions of a 3 bps transaction cost, a 5-day rebalancing frequency, and rolling updates of the factor set.

Empirical results show that the effective GP factors discovered in this paper exhibit positive Rank IC, good monotonicity in stratification, and a positive return spread between the 10th and 1st groups at the single-factor level. At the portfolio level, the top 15 GP factors under a rolling update scheme are equally weighted after cross-sectional z-score standardisation. The resulting portfolio holding 20 stocks achieves, over the out-of-sample period from 2020-09-28 to 2025-12-31, a cumulative return of 103.95%, an annualised return of 19.76%, an excess return over the CSI 500

of 75.30%, and a maximum drawdown of -20.01%. Further comparison of different subsequent signal aggregation models reveals that ElasticNet can improve portfolio net value, but its overall Rank IC is weaker than that of simple equal weighting. XGBoost and fixed-snapshot GRU do not consistently enhance the full-cross-section ranking ability. Overall, the mixed-frequency GP factors themselves contain tradable out-of-sample information. For subsequent signal aggregation, the simple and transparent equal-weighted combination outperforms the currently specified complex models in terms of robustness in translating factor information, making it more suitable as the main conclusion at this stage.

In earlier stages, simple factors mined from daily-frequency fields using GP without time-series functions, followed by a stage-wise model that generated alphas with a GRU, also achieved some predictive effect when evaluated under the unified `raw1d` accounting standard, but the performance fluctuated noticeably across adjacent versions. This suggests that matching between factor complexity and downstream model complexity matters: complex time-series factors may be better paired with simple and transparent aggregation rules, whereas simpler factors may still benefit from stronger sequential models.

Key words: genetic programming, mixed-frequency data, factor mining, minute-level modeling, out-of-sample backtest

目录

第一部分　毕业论文

1　绪论 1
1.1 研究背景 1
1.2 遗传算法与遗传编程简介 2
1.3 本文工作与贡献 5
1.4 论文结构安排 5
2　混合频率遗传编程因子挖掘方法 6
2.1 问题定义与数据描述 6
2.2 函数库设计 8
2.3 遗传操作与选择机制 11
2.4 大规模计算工程实现 12
2.5 后续信号合成模型简介 13
2.6 GRU 模块改进 14
3　实验设计与结果分析 15
3.1 实验目标与评价指标 15
3.2 单因子检验流程 16
3.3 因子组合构建 16
3.4 滚动样本外回测设置 17
3.5 早期日频简单因子的探索 17
3.6 混频单因子检验结果 18
3.7 简单因子组合回测结果 23
3.8 下游模型的补充比较 25
4　结论与展望 28
4.1 研究结论 28
4.2 不足与未来工作 28

5 参考文献 30
作者简历 33
本科生毕业论文（设计）任务书 35
本科生毕业论文（设计）考核 37

第二部分 毕业论文开题报告

一、 文献综述 1
1 背景介绍 1
1.1 自动化因子挖掘 1
1.2 基于深度学习的收益预测 1
1.3 因子挖掘与神经网络融合 2
1.4 存在的问题与研究空间 2
2 研究展望 2
3 国内外研究现状 2
3.1 研究方向及进展 2
3.2 存在问题 3
4 研究展望 3
5 参考文献 5
二、 开题报告 7
1 问题提出的背景 7
1.1 背景介绍 7
1.2 本研究的意义和目的 7
2 项目的主要内容和技术路线 8
2.1 主要研究内容 8
2.2 技术路线 8
2.3 可行性分析 9
3 研究计划进度安排及预期目标 10
3.1 进度安排 10

3.2 预期目标 11
4 参考文献 12
三、 外文翻译 13
1 摘要译文 13
2 方法译文 13
3 实验与结论译文 14
4 评述 14
5 外文翻译小结 15
6 外文翻译参考文献 15
四、 外文原文 19
毕业论文（设计）文献综述和开题报告考核 33

第一部分

毕业论文

1 绪论

1.1 研究背景

时序预测是统计学习与应用数学中的重要问题，而如何从原始观测序列中提取稳定、可解释的预测因子，则是其中一类具有代表性的建模任务。本文以股票收益预测作为实验载体讨论这一问题：早期多因子框架为因子研究提供了统一分析范式[1-2]，近年来机器学习资产定价研究进一步证明了非线性建模对收益预测的增量价值[3]。

在量化领域，当前股票收益的主流预测方法大致可分为两类。

第一类是端到端学习方法。该类方法尽可能保留原始市场数据形态，通过预处理与深度模型联合训练，直接完成特征提取与收益预测，不显式构造中间因子。其优势在于能够利用海量数据学习复杂时空依赖，但局限也较突出：模型可解释性不足，金融业务场景中的可审计性较弱；同时金融数据具有高变异、低信噪比特征，端到端模型更容易拟合噪声[4-5]。

第二类是因子挖掘方法。该类方法通过人工逻辑、遗传编程或强化学习等方式开展特征工程，再使用相对轻量的预测器进行信号合成。公式化因子通常更易解释，也便于诊断、去冗余和维护，因此在研究与实务中都具有较高可用性[6-8]。

因子挖掘完成后，研究者通常还需要构造后续信号合成模型，将多因子信息映射为最终综合得分。现有文献中较常见的选择包括：岭回归（Ridge）与弹性网络（Elastic Net）一类带正则化的线性模型，用于在高相关因子下控制估计方差[3,9]；XGBoost 一类树集成模型，用于捕捉非线性和交互效应[10-11]；以及门控循环单元网络（Gated Recurrent Unit, GRU）、长短期记忆网络（Long Short-Term Memory, LSTM）等循环神经网络，用于建模因子或价格信号的时间依赖结构[4,12]。

一个进一步的问题是，模型复杂性应主要放在因子挖掘阶段还是后续信号合成阶段。现有研究并未给出绝对统一的答案。一方面，当输入仍以基础特征、滞后收益或相对简单的截面信号为主时，树模型、深度网络与时序模型往往能够通过学习非线性关系和动态依赖提升预测性能[3-4,11]。另一方面，若特征构造或因子生成阶段已经较充分地吸收非线性结构、交互项或潜在因子信息，则下游常可借助较低自由度的因子定价、线性组合或排序框架实现较稳健的样本外表现[13-15]。与此同时，近期关于复杂因子模型的研究也表明，更高

复杂度的资产定价模型在某些任务上仍可能继续受益，因此“复杂因子配简单模型”更适合作为一种经验性的设计原则，而非普适定律[16]。

因此，因子挖掘量化选股流程可以拆分为两个相对独立的问题：其一是发现稳定、可解释的候选因子；其二是在控制过拟合的前提下，将候选因子合成为可用于历史检验的预测信号。

在本文的研究资源与实验目标下，端到端路线面临两项现实约束。

其一是算力门槛。分钟级多资产数据下的端到端联合训练通常需要较高算力，单卡消费级 GPU 难以支持充分的滚动实验。

其二是调试成本。复杂模型在失效时较难定位根因，而因子挖掘工具链相对成熟，问题定位路径更直接。这一差异会影响实验迭代速度与可复现实验规模[5,17]。

尽管因子挖掘路线已经较为成熟，现有文献对混合频率输入的探索仍不充分。大量工作以日频因子为主，分钟信息多通过预聚合统计量间接引入[7-8]。围绕分钟频与日频联合建模，尤其是函数库设计、类型安全约束与工程化训练流程，仍存在可扩展空间。

1.2 遗传算法与遗传编程简介

遗传算法（Genetic Algorithm, GA）是一类模拟自然选择与遗传机制的随机优化方法，其基本流程包括种群初始化、适应度评估、选择、交叉与变异[18]。遗传编程（Genetic Programming, GP）是在 GA 基础上的表达式级扩展：它不再仅搜索数值参数，而是直接搜索可执行的数学表达式或程序结构[19-20]。在量化因子挖掘场景下，这意味着模型的输出不是一组难以解释的参数权重，而是一条能够直接解释、复算和部署的因子公式。

1.2.1 表达式树与符号回归

从表示方式上看，GP 通常采用表达式树（expression tree）对候选解进行编码。内部节点表示函数算子，叶节点表示终端变量或常数。例如，若希望表示

$$f(x_1,x_2)=\frac{x_1+x_2}{3} \tag{1-1}$$

则其树形结构可写为图 1.1 所示形式。该表示的优点在于结构高度灵活：只要预先给定算子集合 $\mathcal{O}$ 与终端集合 $\mathcal{V}$，就可以通过不同深度、不同拓扑的树结构表示大规模候选公式

空间[19-20]。

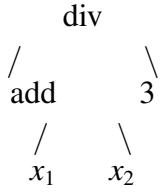


图 1.1 表达式树示意图

若将 GP 视作符号回归（symbolic regression）问题，则其本质是在给定样本 (X,y) 的条件下，在表达式空间 $\mathscr{E}$ 中搜索最优公式：

$$f^* = \arg\min_{f\in\mathscr{E}} \mathscr{L}(f(X),y) + \lambda\Omega(f) \tag{1-2}$$

其中 $\mathscr{L}$ 表示预测误差或排序误差，$\Omega(f)$ 表示复杂度惩罚。与传统回归模型先固定函数形式、再估计参数不同，GP 同时搜索“结构”与“参数”，因此更适合发现人类难以事先枚举的非线性组合关系[8,21-22]。

在具体实现上，常见 GP 系统还会区分 full、grow 与 ramped half-and-half 等初始化策略，以平衡首代种群的树深、宽度和结构多样性[19-20]。对量化因子挖掘而言，这一步的重要性在于：如果初始表达式过于单一，搜索容易早熟收敛；如果初始表达式过于复杂，则后续会付出较高的计算和稳健性代价。

1.2.2 演化流程与遗传操作

GP 的标准流程可以概括为“生成种群、评估适应度、选择父代、产生子代、迭代更新”五个步骤。设第 g 代种群为 $\mathscr{P}^{(g)} = \{f_1,\dots,f_M\}$，则算法在每一代都会先根据适应度函数 $\Phi(f)$ 对个体打分，再通过选择机制保留较优个体，并借助交叉与变异产生下一代候选解。一个简化后的流程如图 1.2 所示。

其中，选择机制常见于锦标赛选择（tournament selection）：从种群中随机抽取若干个体，选择其中适应度最优者作为父代。遗传操作通常由交叉、子树变异、提升变异、点变异与繁殖五类机制构成[19-20,23]。交叉在两个父代树中各选一个子树并交换，用于组合已有的有效结构；子树变异用一棵新随机生成的子树替换原树的局部，以增强全局探索能力；提

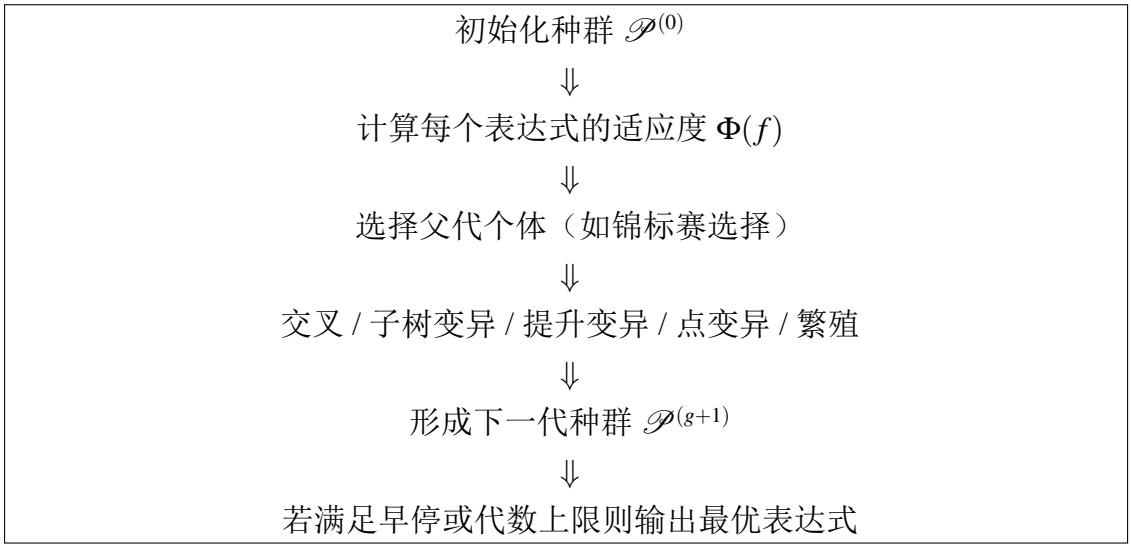


图 1.2 遗传编程演化流程示意图

升变异从已有子树中提升较小分支替换原结构，以抑制无意义膨胀；点变异仅替换某个节点本身而不改动其余拓扑，属于更细粒度的局部搜索；繁殖则直接复制当前优质个体，避免有价值结构在下一代完全丢失。

在量化选股任务中，适应度函数通常不直接使用均方误差，而更关注横截面排序能力、收益稳健性与复杂度约束。例如，一个概念性的适应度函数可以写为

$$\Phi(f) = S(f) - \lambda_c C(f) - \lambda_r R(f) \tag{1-3}$$

其中 $S(f)$ 代表预测能力指标，如 Rank IC；$C(f)$ 代表表达式复杂度；$R(f)$ 代表风险或不稳定性惩罚。这样的设计能够让演化方向更贴近实际因子研究的目标，而不是单纯追求样本内拟合度[5,7-8]。

1.2.3 GP 在因子挖掘中的优势与局限

在量化因子挖掘任务中，GP 的核心优势在于能够同时完成“因子结构发现”和“参数组合搜索”，输出结果为可解释的公式化因子，便于事后诊断、去冗余和策略维护[6-7]。与端到端深度模型相比，这类表达式可以被直接检查其经济含义，例如是否刻画了订单流不平衡、波动扩散、尾盘成交特征或资金流方向等信息。

但 GP 同样存在公认难点。首先，表达式树在迭代中容易出现代码膨胀（bloat），即复杂度不断上升但有效信息没有同步增加；其次，若搜索空间不受约束，演化过程容易在样

本内偶然模式上过拟合，导致样本外显著回落；再次，金融数据具有强噪声、弱信号和非平稳特征，适应度本身也会随市场环境变化而波动[5,20-21]。因此，现代 GP 因子挖掘框架通常会叠加强类型函数库、复杂度惩罚、多样性约束、滚动样本外验证与基于已有结果的初始化机制，以在搜索效率和样本外稳健性之间取得平衡[5,8]。

除学术研究外，实务界也开始将 GP 用于高频因子自动化挖掘。例如，方正证券提出了基于 Dask 计算图的 GP 高频因子挖掘框架，强调分钟频与日频混合输入、分块存储、按需计算以及覆盖度与多样性约束，这与本文关注的工程问题具有较高相似性[23]。本文的方法设计正是在这些通用 GP 原理与量化因子挖掘实践之间建立联系，并进一步面向混合频率输入场景做出针对性改造。

1.3 本文工作与贡献

本文围绕时序预测中的因子挖掘模拟方法，重点讨论从早期日频探索到混合频率 GP 改进的研究路径。以股票收益预测为验证场景，本文的主要贡献体现在以下几个方面。首先，本文提出了面向混合频率表达式树的强类型 GP 框架，对分钟张量与日频矩阵的合法组合进行约束，从而减少无效搜索。其次，本文设计了由分钟保持算子、分钟时序函数、日内聚合函数和日频层函数组成的算子体系，以提升跨频率表达能力。再次，本文构建了以 Rank IC 为核心、结合 IC 阈值、分层单调性和相似度约束的因子筛选与归档机制，用于控制冗余并保留有效表达式。在工程实现上，本文基于 `numpy.memmap` 与分层并行机制完成大规模分钟张量处理，缓解了混合频率数据在存储与计算上的瓶颈。最后，本文建立了滚动更新因子集合、固定股票池和统一逐日记账口径的样本外评估流程，并比较了简单组合、正则化线性模型与时序模型在信号合成上的表现差异。

1.4 论文结构安排

全文结构如下：第 2 章介绍混合频率 GP 因子挖掘框架、函数库设计、工程实现以及后续信号合成模型；第 3 章在说明数据处理、单因子检验、因子组合构建与滚动样本外评估设定后，依次汇报早期日频阶段结果、混频单因子检验结果、因子组合回测结果及其与后续监督模型的比较；第 4 章总结全文工作，并给出后续研究方向。

2 混合频率遗传编程因子挖掘方法

2.1 问题定义与数据描述

参考公式化因子挖掘与遗传进化因子搜索的常见设定，本文将问题表述为如下优化任务[5,7,23]。记终端变量集合为 $\mathcal{V}$，算子库为 $\mathcal{O}$。本文希望在可计算表达式空间 $\mathcal{E}$ 中搜索横截面预测能力尽可能强、且具备可解释性的因子表达式 f^*。在本文实现中，候选表达式的优劣由样本内调仓日的平均横截面 Rank IC 衡量，因此优化目标可写为

$$f^* = \arg\max_{f\in\mathcal{E}} \Phi(f), \qquad \Phi(f) = \frac{1}{|\mathcal{D}|}\sum_{\tau\in\mathcal{D}} \rho_s\left(f_\tau, y_\tau\right), \tag{2-1}$$

其中，$\mathcal{D}$ 表示训练窗口内的调仓日集合，$\rho_s(\cdot,\cdot)$ 表示 Spearman 秩相关系数，f_τ 与 y_τ 分别表示第 τ 个调仓日在股票横截面上的因子值与未来收益标签。该定义与本文后续 Top-N 排序选股的交易目标保持一致，即更关注横截面排序能力，而非绝对收益数值的点预测精度。

为避免后文时间索引混淆，本文统一用 τ 表示实际调仓入场日，用 $s(\tau)$ 表示其前一交易日。配置文件中 `signal_to_entry_days=1`，因此在调仓日 τ 使用的因子值 f_τ 实际由截至 $s(\tau)$ 可观测的日频与分钟频数据计算，再在 τ 日执行入场。5 日训练标签和 1 日逐日记账收益都按入场日 τ 对齐。

本文数据来源于敦和资管内部数据库，覆盖日频与分钟频两层市场信息。敦和资产管理有限公司是一家中国本土成长起来的、致力于国内外资本市场投资的全球宏观私募基金公司。

实验样本区间为 2019 年 1 月 2 日至 2025 年 12 月 31 日的市场交易日。出于对于内存占用和模型训练时长的考虑，回测选择在中证 500 股票池上进行。

中证 500 指数在沪深 300 指数样本空间基础上，剔除沪深 300 成分股及过去一年日均总市值排名前 300 的证券后，再对剩余证券进行流动性筛选，并按过去一年日均总市值选取前 500 只证券构成，反映 A 股市场中小市值股票的整体表现[24]。由于成分股理想、行业均衡，量化策略普遍以中证 500 为基准。

出于方便，股票池并非逐日固定 500 只成分股（可作为后续改进方向），而是首先依据中证 500 成分股数据构造样本区间内中证 500 历史成分股并集，再与日频字段共同可用股

票集合对齐；在混频三维管线中，为保证分钟张量与日频矩阵在股票维度上严格一致，进一步仅保留同时存在于分钟缓存支持列中的股票形成最终股票池。

在监督标签上，本文采用 neu_all_vwap_5d。该字段以“调仓日早盘前 30 分钟 VWAP 买入、持有 5 个交易日后于早盘前 30 分钟 VWAP 卖出”的交易流程来定义未来收益，并在此基础上使用中性化版本作为训练与评估目标。设第 τ 个调仓日早盘前 30 分钟的成交量加权平均价为

$$\mathrm{VWAP}_{\tau}^{am30}=\frac{\sum_{m=1}^{30}P_{\tau,m}V_{\tau,m}}{\sum_{m=1}^{30}V_{\tau,m}} \tag{2-2}$$

其中，$P_{\tau,m}$ 与 $V_{\tau,m}$ 分别表示第 τ 日第 m 个分钟片段的成交价与成交量，则按入场日对齐的 5 日持有期原始收益可写为

$$y_{\tau}=\frac{\mathrm{VWAP}_{\tau+4}^{am30}}{\mathrm{VWAP}_{\tau}^{am30}}-1 \tag{2-3}$$

进一步经横截面中性化处理后得到 neu_all_vwap_5d。若改用前一交易日 $s(\tau)$ 作为信号索引，则上式等价于 $\mathrm{VWAP}_{s+5}^{am30}/\mathrm{VWAP}_{s+1}^{am30}-1$。这一标签设计的关键优点在于：信号生成时点严格早于入场时点，入场与离场价格均对应可观测成交区间，因此兼顾了可交易性与前视偏差控制，保证了回测结果的有效性。

在原始输入层面，本文采用“日频面板 + 原生分钟张量”的混频结构，而非先将分钟信息聚合为日频因子后再做普通二维 GP。

日频字段共 99 个。整体上看，这些变量主要覆盖五类信息：其一是基础行情与规模流动性字段，如 close、open、high、low、pct_chg、vol、amount、turnover_rate、total_mv 与 circ_mv，用于刻画价格、成交活跃度与市值规模；其二是主力资金净流入字段，如 S_MFD_INFLOW、S_MFD_INFLOW_LARGE_ORDER、S_MFD_INFLOWVOLUME，以及 NET_INFLOW_RATE_VALUE、NET_INFLOW_RATE_VOLUME 等，用于描述资金净流向及其时段结构；其三是分档买卖与主动成交字段，对超大单、大单、中单、小单分别记录买卖金额、成交量和成交笔数，并保留主动成交版本 _ACT，用于刻画不同资金规模和成交主动性下的订单流结构；其四是差分与比率类资金流字段，包括 VALUE_DIFF_*、VOLUME_DIFF_* 与 MONEYFLOW_PCT_* 等，覆盖小单、中单、大单与机构维度，用于刻画买卖力量差异和资金偏向；其五是估值与成交行为补充字段，如 s_val_pb_new，以及 VOLUME_RATIO、VOLUME_BREAK、VOLUME_MOMENTUM 的多窗口版本，用于补充估值状态与成交量行为特征。

分钟层使用 1 分钟频率的原生缓存字段，共 128 个，在表达式求值时统一加 min_ 前缀。其内容同样可以概括为若干互补维度：基础 K 线与成交活跃度字段包括 Open、High、Low、Close、Volume、Dolvol、TradeCount、TickCount、CloseRatio 与涨跌停价字段；微观结构统计字段包括 SpreadMean、SpreadStd、DolvolMean、DolvolStd、AskVolumeMean、BidVolumeMean、MidTickTurnover 与 RetStd;分段收益与状态拆分字段如 RetByDolvolTopHalf、RetByDolvolBottomHalf、RetByQRRTopHalf、RetByQRRBottomHalf、RetUp 与 RetDown，用于描述分钟收益在不同成交状态下的异质性;此外还记录 Buy/Sell 与 CancelBuy/CancelSell 对应的笔数、成交量和成交额，以刻画订单流方向与撤单行为；对 Large、Big、Median、Small 四档资金分别记录买卖量、成交额和笔数，并进一步细分为 Active 与 Passive 版本，用于捕捉不同交易主体和成交方式下的微观结构差异。

分钟缓存按 minute_cache/year/month/day/ 目录组织。每个交易日单独保存 minute_tensor.npy、stocks.npy、minutes.npy、fields.npy 与 manifest.json。minute_tensor.npy 的单日形状为 stock×minute×field；在本文配置下，分钟区间覆盖 09:30–15:00 的 1 分钟数据，字段数为 128。原始单日缓存中的股票行数可能因当天分钟数据可用性而略有变化，但在训练与回测求值时，代码会先将其映射回统一的股票固定列顺序，再在逻辑上拼接成 date×stock×minute×field 的四维张量，从而在保留分钟级信息的同时控制内存占用并支持大规模混频表达式搜索。

2.2 函数库设计

混合频率数据对 GP 的类型安全提出严格要求。若不加约束，演化会产生大量非法表达式，例如将分钟序列与日频标量直接相加，或在日频矩阵上执行分钟轴操作。为此，本文设计了类型受约束的函数库。

类型系统定义两种基础类型：minute_tensor 与 daily_matrix。前者表示含分钟维度的数据，后者表示聚合后的日频矩阵。每个函数均显式声明输入与输出类型，表达式树生成过程据此执行合法组合约束。

图 2.1 给出了混频 GP 表达式的一个典型结构。分钟频终端变量只能先经过分钟保形算子与时序算子变换，再通过桥接层 reducer 压缩为日频对象；此后才能和日频终端变量一起进入日频层函数。根节点输出必须是日频，这样才能与日频收益标签做横截面匹配。

该约束的作用是把“分钟到日频”的跨频率转换集中在 reducer 一层，避免生成语义不清或根本不可计算的表达式。

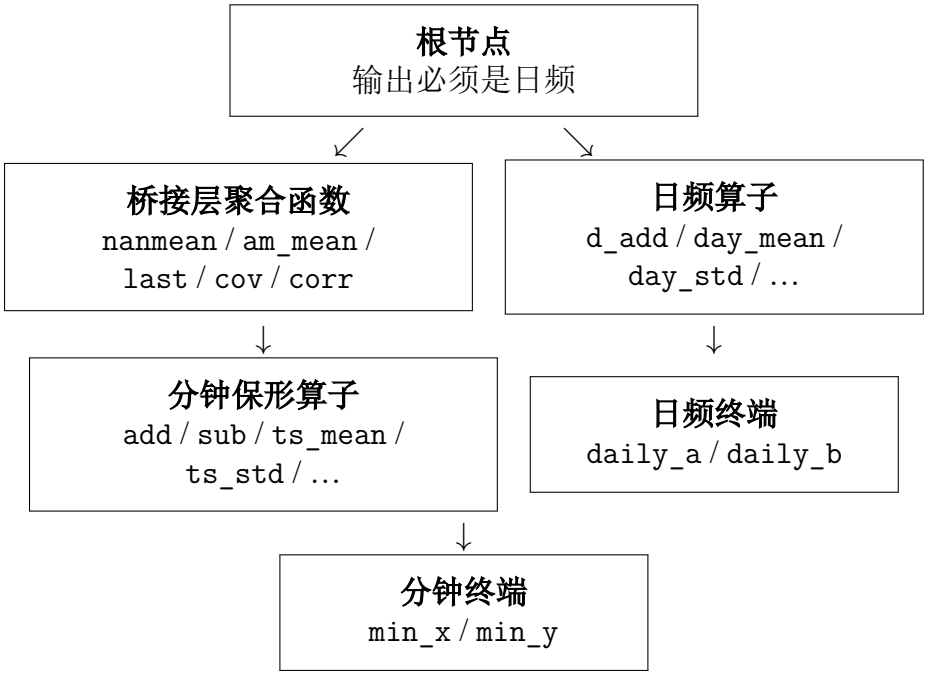


图 2.1 混频 GP 表达式的类型约束与跨频率桥接结构

在上述强类型约束下，单棵表达式树最终可归纳为三类结构：

$$F_{\text{daily}} = g_d(d_1, d_2, \ldots, d_n) \tag{2-4}$$

$$F_{\text{minute}} = R\big(g_m(m_1, m_2, \ldots, m_k)\big) \tag{2-5}$$

$$F_{\text{mix}} = g\Big(g_d(d_1, \ldots, d_n),\, R\big(g_m(m_1, \ldots, m_k)\big)\Big) \tag{2-6}$$

其中，g_d 表示日频函数组合，g_m 表示分钟频函数组合，R 表示日内聚合算子。三类结构分别对应纯日频因子、纯分钟频因子以及日频与分钟频联合构造的混频因子，也与后文单因子展示中的类别划分保持一致。

2.2.1 分钟保持算子

分钟保持算子输入输出均为 `minute_tensor`。其中，二元逐元素运算包括 `add`、`sub`、`mul`、`div`、`max` 与 `min`；一元逐元素变换包括 `abs`、`log` 与 `sqrt`；分钟轴变换则包括 `diff`、`zscore` 与 `signedpower`。

这类算子在代码中采用受保护定义，以保证表达式对异常输入仍有确定输出。对任意分钟张量元素 x, x_1, x_2，有

$$\texttt{div}(x_1, x_2) = \begin{cases} x_1 / x_2, & |x_2| > 10^{-6}, \\ 0, & |x_2| \le 10^{-6}, \end{cases} \tag{2-7}$$

$$\texttt{log}(x) = \begin{cases} \log|x|, & |x| > 10^{-6}, \\ 0, & |x| \le 10^{-6}, \end{cases} \qquad \texttt{sqrt}(x) = \sqrt{|x|}, \tag{2-8}$$

$$\texttt{signedpower}(x) = \operatorname{sign}(x)\,|x|^2. \tag{2-9}$$

此外，`diff` 在分钟轴上一阶差分，并把每个交易日的首个分钟位置填为缺失值；`zscore` 则沿分钟轴做标准化，当该日该股票对应分钟序列标准差不超过 10^{-12} 时，将分母回退为 1。

2.2.2 分钟时序函数

分钟时序函数同样保持 `minute_tensor` 类型不变，在分钟轴上执行窗口计算。窗口参数采用 5、10、20 三组，具体包括分钟轴滞后算子 `ts_delay_k`、当前值与 k 分钟前值之差 `ts_delta_k`、k 分钟滚动均值 `ts_mean_k` 与 k 分钟滚动标准差 `ts_std_k`。

2.2.3 日内聚合函数

日内聚合函数将 `minute_tensor` 压缩为 `daily_matrix`。按逻辑可分为三类：第一类是全日聚合，如 `nanmean`、`nanstd`、`q10/q50/q90`、`nanmax`、`nanmin`、`range`、`sum`、`last`、`argmax` 与 `argmin`；第二类是分段聚合，如 `am_mean/std/range`、`pm_mean/std/range`、`mid_mean/std/range` 以及 `open15/open30`、`close15/close30` 等窗口统计；第三类是结构化聚合，包括 `cov`、`corr`、`am_beta`、`pm_beta`、`mean_spread`、`am_pm_spread`、`midday_reversal` 与 `weighted_mean`。

为便于解释后文出现频率较高的表达式，下面给出若干核心聚合算子的精确定义。设单日分钟序列长度为 M，分钟索引为 $m = 1, \ldots, M$，前 30 分钟集合记为 $\mathscr{H}_{30} = \{1, \ldots, \min(30, M)\}$，尾盘 30 分钟集合记为 $\mathscr{T}_{30} = \{\max(1, M-29), \ldots, M\}$，分钟轴前半段与后半段分别记为 $\mathscr{A}$ 与 $\mathscr{P}$。则

$$\texttt{close30_mean}(x) = \frac{1}{|\mathscr{T}_{30}|} \sum_{m \in \mathscr{T}_{30}} x_m, \qquad \texttt{open30_mean}(x) = \frac{1}{|\mathscr{H}_{30}|} \sum_{m \in \mathscr{H}_{30}} x_m, \tag{2-10}$$

$$\texttt{mean_spread}(x,y)=\frac{1}{M}\sum_{m=1}^{M}(x_m-y_m) \tag{2-11}$$

$$\texttt{weighted_mean}(x,w)=\begin{cases}\frac{\sum_{m=1}^{M}x_m w_m}{\sum_{m=1}^{M}w_m}, & \left|\sum_{m=1}^{M}w_m\right|>10^{-12},\\ 0, & \text{否则},\end{cases} \tag{2-12}$$

$$\texttt{am_beta}(x,y)=\frac{\mathrm{Cov}(x_m,y_m;\,m\in\mathscr{A})}{\mathrm{Var}(y_m;\,m\in\mathscr{A})},\qquad \texttt{pm_beta}(x,y)=\frac{\mathrm{Cov}(x_m,y_m;\,m\in\mathscr{P})}{\mathrm{Var}(y_m;\,m\in\mathscr{P})}, \tag{2-13}$$

其中分母不超过 10^{-12} 时回退为 0。又令午前后两个分段分别为 $\mathscr{M}_1=[0.25M,0.5M)$ 与 $\mathscr{M}_2=[0.5M,0.75M)$ 对应的分钟索引集合，则

$$\texttt{midday_reversal}(x)=\frac{1}{|\mathscr{M}_2|}\sum_{m\in\mathscr{M}_2}x_m-\frac{1}{|\mathscr{M}_1|}\sum_{m\in\mathscr{M}_1}x_m. \tag{2-14}$$

2.2.4 日频层函数

日频层函数作用于 `daily_matrix`，用于日频组合与变换。其中，二元运算包括 `d_add`、`d_sub`、`d_mul`、`d_div`、`d_max` 与 `d_min`；一元变换包括 `d_abs`、`d_log`、`d_sqrt` 与 `d_sign`；此外还引入 `d_absdiff`、`d_ratio` 与 `d_norm_spread` 等复合运算，其中归一化价差函数定义为

$$\mathrm{NormSpread}(x_1,x_2)=\frac{x_1-x_2}{|x_1|+|x_2|} \tag{2-15}$$

在代码实现中对应 `d_norm_spread`，当分母趋近于零时回退为零。

2.3 遗传操作与选择机制

适应度评价以横截面 Spearman 秩相关为核心。具体而言，本文对候选因子逐日计算横截面 IC，再取均值作为基础评分。选择平均 Rank IC 而非均方误差、Pearson 相关或样本内累计收益，主要有三点原因：第一，本文任务本质上是横截面选股排序，秩相关比绝对数值误差更贴近 Top-N 选股目标；第二，金融收益分布常伴随厚尾、极端值与异方差，Spearman 相关对离群点和尺度变化更稳健；第三，直接优化样本内净值容易放大交易路径噪声，使演化过程过度贴合特定市场片段。

每轮演化后，候选因子需通过双层筛选。第一层为 IC 阈值筛选，即适应度不低于 ga_min_ic_threshold；第二层为相似度去冗余，即与入选集合的最大相关度不高于 ga_max_similarity_threshold。

通过筛选的因子按适应度降序排列，每轮最多新增 ga_factors_per_iteration 个。

其中相似度硬筛直接基于因子预测序列本身而非表达式字符串。设候选因子 f 与已入选因子 g 在训练窗口调仓日 $\tau \in \mathscr{D}$ 上的横截面得分分别为 f_τ, g_τ，则代码首先逐日计算横截面 Spearman 相关，再按与适应度一致的时间聚合规则汇总。对本文主实验所用的 `signed_mean_ic` 设定，有

$$\mathrm{Sim}(f,g) = \frac{1}{|\mathscr{D}|} \sum_{\tau \in \mathscr{D}} \rho_s(f_\tau, g_\tau). \tag{2-16}$$

只有当 $\max_{g \in \mathscr{S}} \mathrm{Sim}(f,g) \le$ ga_max_similarity_threshold 时，候选因子 f 才会被加入已入选集合 $\mathscr{S}$。因此，这一步控制的是训练窗口内横截面排序结构的重复程度。

在终端节点采样时，本文还允许表达式树引入随机常数项，当前设置为

$$\texttt{const_range} = (-1.0,\ 1.0) \tag{2-17}$$

即常数从区间 $[-1, 1]$ 中随机采样，用于提升表达式局部缩放、平移与归一化组合的灵活性，但不额外扩展终端类型系统。

2.4 大规模计算工程实现

分钟频引入后，训练张量规模显著提升。若直接将相关四维张量全量载入内存，常会超出普通服务器可承载范围。本文采用 `numpy.memmap` 在磁盘建立逻辑数组并按需映射切片，显著降低峰值内存占用。分钟缓存布局同样面向 memmap 访问优化。核心数据文件为 `minute_tensor.npy`，轴信息与元数据则单独存放。`manifest.json` 记录张量形状、数据类型与交易日元信息。构建阶段使用 `open_memmap` 写入，读取阶段使用 `mmap_mode='r'` 按页加载。

并行化实现分为三层：首先，在分钟 cache 读取阶段使用 `ThreadPoolExecutor` 线程池并配合预取队列抑制瞬时内存冲高；其次，在特征归一化阶段按特征维切分任务，由多个 worker 并行计算全局统计量；最后，在 GP 演化阶段基于 `joblib` 对种群分块评估，并进行周期性个体迁移以保持多样性。

2.5 后续信号合成模型简介

GP 负责从原始分钟频与日频字段中发现候选表达式，但最终交易仍需要后续映射，将多因子截面 $\mathbf{z}_{t,i} \in \mathbb{R}^K$ 转换为股票 i 在时点 t 的综合得分 $\hat{y}_{t,i}$。考虑到本文的主要目标是检验 GP 因子本身的样本外有效性，正文以简单模型作为基线，并在后文实验结果部分补充比较更复杂的监督模型。

第一类是简单线性聚合。对每个调仓日的因子截面先做 z-score 标准化，再取等权平均：

$$\hat{y}_{t,i} = \frac{1}{K} \sum_{k=1}^{K} \frac{f_{k,t,i} - \mu_{k,t}}{\sigma_{k,t}} \tag{2-18}$$

其中 $\mu_{k,t}$ 与 $\sigma_{k,t}$ 分别表示第 k 个因子在当日横截面上的均值与标准差。该方法不额外估计参数，可解释性强，也便于把回测表现直接归因于 GP 因子质量本身。

第二类是带正则化的线性模型，包括 Ridge 和 Elastic Net。其核心思想是在截面回归中加入系数收缩项，以缓解高相关因子导致的估计不稳定[3,9]。其中 Elastic Net 的目标函数可写为

$$\min_{\beta} \frac{1}{n} \sum_{j=1}^{n} (y_j - \beta_0 - \mathbf{z}_j^{\top} \beta)^2 + \lambda \left[(1-\alpha) \frac{\|\beta\|_2^2}{2} + \alpha \|\beta\|_1 \right] \tag{2-19}$$

当 $\alpha = 0$ 时退化为 Ridge，当 $\alpha = 1$ 时接近 Lasso。此类模型仍保持线性可解释性，但允许通过收缩或稀疏化提升头部选股稳定性。

第三类是树集成模型。以 XGBoost 为代表，其通过多棵回归树的加法结构拟合非线性映射

$$\hat{y}_{t,i} = \sum_{m=1}^{M} g_m(\mathbf{z}_{t,i}), \qquad g_m \in \mathcal{G} \tag{2-20}$$

并在目标函数中同时加入经验损失与树复杂度惩罚[10]。这类模型能够捕捉因子之间的非线性关系与交互项，但对样本规模、特征分布和超参数更敏感。

第四类是时序神经网络模型。GRU 将历史多期因子序列 $\{\mathbf{z}_{t-L+1,i}, \ldots, \mathbf{z}_{t,i}\}$ 编码为隐状态，再输出下一期预测值，其门控更新机制可写为[12]

$$\mathbf{h}_t = (1 - \mathbf{u}_t) \odot \mathbf{h}_{t-1} + \mathbf{u}_t \odot \tilde{\mathbf{h}}_t \tag{2-21}$$

其中 $\mathbf{u}_t$ 为更新门，$\tilde{\mathbf{h}}_t$ 为候选隐状态。相较于静态截面模型，GRU 更适合利用因子时间演化信息，但也引入了更高的训练成本和更强的模型自由度。

从文献与实证经验看，后续模型并不存在绝对统一的最优答案。若输入仍以较基础的原始特征或简单因子为主，树模型、深度网络和时序模型往往能够通过学习非线性与动态依赖关系取得增量收益[3-4,11]。但若上游因子构造阶段已经较充分地压缩了原始信息、吸收了交互项和潜在风险结构，则下游采用较低自由度的因子定价或线性组合框架，往往更有利于稳健实现样本外表现[13-15]。同时，关于大型因子模型的研究也提醒我们，更高复杂度并不必然有害，在特定资产定价任务中甚至可能继续提升样本外效果[16]。因此，本文将“复杂因子配简单组合”作为正文主实验基线，同时保留“较简单因子配时序模型”的早期探索路径，并把 Ridge、Elastic Net、XGBoost 与固定快照 GRU 作为补充比较，而不把某一类复杂模型视为结论成立的必要条件。

2.6 GRU 模块改进

在因子挖掘结果基础上，由于较为复杂的下游模型调参较为困难，本文同步优化 GRU 预测模块训练流程。首先，将表达式计算得到的因子张量按 `sequence_length` 组织历史序列输入，以未来 `predict_days` 收益作为监督目标，并默认执行截面标准化。其次，样本按时间顺序切分为前 80% 训练集与后 20% 验证集，训练中使用 Adam 优化、MSE 损失、`ReduceLROnPlateau` 与早停机制。

此外，针对早停后的模型使用逻辑进行了修正：回测阶段不再直接使用最后一轮模型，而是显式回退到验证集表现最优轮次的模型参数，以保证训练目标与实盘选股模型的一致性。

3 实验设计与结果分析

3.1 实验目标与评价指标

本文实验分为两部分。第一部分展示早期日频阶段导出的日度预测信号，用于考察“无时序信息因子 + 时序模型”这一研究路径的可行性。第二部分是对混合频率 GP 挖掘出的公式因子进行正式样本外检验。为减少后续模型自由度对结论的干扰，正文主实验采用“因子标准化后简单组合”的方式构造预测信号；正则化线性模型、树模型与 GRU 的结果仅作为补充比较，用于分析不同信号合成方式对因子信息的转化效率。

在因子层面，核心评价指标为横截面秩相关信息系数（Rank Information Coefficient, Rank IC）及其信息比率（Information Coefficient Information Ratio, ICIR）。设第 τ 个调仓入场日的因子截面为 f_τ、5 日训练标签截面为 y_τ，则当日 Rank IC 定义为

$$\mathrm{IC}_\tau^{(5)} = \mathrm{Spearman}(f_\tau, y_\tau) \tag{3-1}$$

开发区间的平均 IC 为

$$\overline{\mathrm{IC}}^{(5)} = \frac{1}{T}\sum_{\tau=1}^{T} \mathrm{IC}_\tau^{(5)} \tag{3-2}$$

对应 ICIR 定义为

$$\mathrm{ICIR}^{(5)} = \frac{\overline{\mathrm{IC}}^{(5)}}{\sigma(\mathrm{IC}^{(5)})} \tag{3-3}$$

需要区分的是，单因子检验中的 5 日 Rank IC 衡量单个表达式与 5 日训练标签之间的横截面排序关系；组合层面的 1 日 Rank IC 则衡量后续信号合成模型输出的综合得分与 `raw1d` 当日逐日记账收益之间的排序关系。代码实现中，这两个指标都按调仓入场日 τ 记账，而因子值本身使用上一交易日可观测的数据计算。因此，本文同时报告 5 日 Rank IC 与 1 日 Rank IC，其中前者更贴近训练目标 `neu_all_vwap_5d`，后者更能反映组合信号在逐日记账口径下的即时排序能力。在比较不同后续模型时，组合的 1 日 Rank IC 是衡量因子信息被转化为交易信号效率的重要指标。

在策略层面，正文重点报告总收益、年化收益率、最大回撤、相对中证 500 基准的超额收益以及组合信号的 1 日 Rank IC，并结合调仓频率与交易成本讨论策略的可交易性。

3.2 单因子检验流程

为检验 GP 因子本身的样本外有效性，本文参考机器学习选股研究中常用的单因子检验方式，对历史生成的 GP 因子池进行事后稳健性测试。测试统一使用同时具备日频字段与分钟缓存支持列的股票池股票，因子值在调仓日前一交易日计算，并在下一调仓入场日与标签对齐；目标标签为中性化 5 日 VWAP 收益 `neu_all_vwap_5d`，组合收益使用未中性化 `raw1d` 逐日记账，调仓频率为 5 个交易日，交易成本按万三计入。

在候选集合上，本文先要求因子 Rank IC 不低于 0.03，并结合十分组收益的单调性与第 10 组和第 1 组收益差进行筛选。这里的“分层单调性”采用代码中的十组累计净收益 Spearman 相关定义：若记第 g 组在全样本期内的累计净收益为 $R_g(f)$，则

$$\mathrm{Mono}(f)=\rho_s\big((1,2,\ldots,10),\,(R_1(f),R_2(f),\ldots,R_{10}(f))\big). \tag{3-4}$$

“第 10 组和第 1 组收益差”则按逐日构造的 G10 多头、G1 空头净收益序列累计得到，并对多头端与空头端分别计入调仓成本。

3.3 因子组合构建

为检验 GP 因子的样本外预测能力，本文对滚动 GA 产出的头部因子进行横截面标准化后等权组合。

设第 j 次滚动 GA 后保留下来的前 K 个因子为 $\{f_{j,1},\ldots,f_{j,K}\}$。在调仓日 τ，先使用调仓日前一交易日可观测到的全部特征，分别计算这些因子的横截面取值，并做标准化：

$$z_{j,k,\tau}(i)=\frac{f_{j,k,\tau}(i)-\mu_{j,k,\tau}}{\sigma_{j,k,\tau}} \tag{3-5}$$

其中 i 为股票，$\mu_{j,k,\tau}$ 与 $\sigma_{j,k,\tau}$ 分别为当日该因子在横截面上的均值与标准差。随后定义组合得分为

$$s_\tau(i)=\frac{1}{K}\sum_{k=1}^{K}z_{j,k,\tau}(i) \tag{3-6}$$

记得分最高的 N 只股票集合为 H_τ，并按 $s_\tau(i)$ 从高到低排序后等权持有，即

$$w_\tau(i)=\frac{\mathbf{1}\{i\in H_\tau\}}{N} \tag{3-7}$$

本文主结果取 $K=15$、$N=20$，同时报告 $K=5$、$N=20$ 作为敏感性对照。

3.4 滚动样本外回测设置

实验遵循严格的滚动样本外流程。代码先用最早 18 个月历史样本训练第一批 GA 因子，再按自上次训练截止日满 18 个月后的第一个调仓日刷新因子库。对于正文主实验，这一规则对应的因子切换日依次为 2022 年 1 月 10 日、2023 年 7 月 14 日和 2025 年 1 月 14 日，因此样本外区间被自然分为 4 段，每一段只使用当时已经生成的因子集合。

组合收益记账采用 1 日频 `raw1d` 口径逐日记账，并统一使用单利累计。设 $r_d^{raw1d}(i)$ 表示第 d 个交易日股票 i 的 1 日原始收益，TO_d 表示调仓换手率，交易成本费率 $c = 0.0003$（万三佣金），则组合当日收益写为

$$r_d^p = \sum_i w_{\tau(d)}(i)\, r_d^{raw1d}(i) - c \cdot \mathrm{TO}_d \tag{3-8}$$

其中 $\tau(d)$ 表示覆盖交易日 d 的最近一次调仓日。由于采用单利模式，组合净值满足

$$V_d = V_0 \left(1 + \sum_{u \le d} r_u^p \right) \tag{3-9}$$

若改用复利口径，则对应净值过程可写为

$$\widetilde{V}_d = V_0 \prod_{u \le d} (1 + r_u^p). \tag{3-10}$$

本文正文统一采用单利记账，目的是在不同模型比较时不额外引入“收益自动再投资”的假设，并使逐日收益贡献与交易成本影响更容易直接比较。需要说明的是，单利口径并不在理论上构成复利口径的严格下界；但对本文主结果对应的 2020-09-28 至 2025-12-31 样本外日度净收益序列而言，若在相同持仓路径与交易成本设定下改按复利累计，则累计收益为 151.38%，高于正文单利口径下的 103.95%。因此，就本文这一版本的主策略结果而言，单利展示确实更为保守，但这一比较依赖于本文样本路径本身，不宜外推为一般规律。基准收益采用同区间中证 500 指数逐日收益。

在上述统一设定下，下面依次给出早期日频探索、混频单因子检验、简单因子组合回测以及不同下游模型的比较结果。

3.5 早期日频简单因子的探索

除最终形成的混合频率 GP 主实验外，本文也展示早期纯日频字段经由无时序函数的 GP 生成简单因子、再由 GRU 进行预测的结果。该部分统一采用中证 500 股票池、`raw1d`

表 3.1 GP 因子组合主回测的核心配置

配置项	设置
股票池	2019 年以来中证 500 历史成分股并集，与分钟缓存及日频字段完整性取交集后得到固定股票池
因子更新方式	首次用前 18 个月样本生成 GA 因子，之后每满 18 个月滚动刷新一次，共形成 4 段历史因子归档
训练标签	中性化 5 日 VWAP 收益 `neu_all_vwap_5d`
信号构造	前 K 个 GP 因子横截面 z-score 标准化后等权平均，正文主结果取 $K=15$，并报告 $K=5$ 对照
持仓构造	每次调仓买入得分最高的 20 只股票，组合内等权配置
调仓频率	每 5 个交易日调仓一次，`signal_to_entry_days=1`
收益记账	使用 1 日收益字段 `raw1d` 逐日记账，单利累计
交易成本	按换手计入万三佣金，即 $c=0.0003$
业绩基准	中证 500 指数

逐日记账、5 日调仓和万三交易成本，样本外回测区间为 2020-09-18 至 2025-12-31。结果表明，简单无时序信息的因子与时序模型结合后能够产生一定预测效果；但相邻版本之间的表现波动较大，反映出以 GRU 为代表的黑盒模型在这一阶段仍存在稳健性不足的问题。

表 3.2 早期日频探索导出的预测信号在统一 `raw1d` 单利口径下的补充结果

历史版本	单利 总收益	单利 年化收益	单利 最大回撤
V1	158.99%	30.09%	-23.70%
V2	128.54%	24.33%	-28.48%
V3	127.91%	24.21%	-25.51%
V4	108.42%	20.52%	-34.97%

出于可比性，表中仅汇报单利口径指标；作为参考，V1 与 V2 在复利口径下的累计收益分别为 310.41% 与 205.70%，对应年化收益为 30.63% 与 23.55%。表 3.2 表明，早期日频探索在统一收益统计规则下仍然具有可观的正向收益；但这一阶段结果的离散程度也较明显，说明其稳定性仍有待进一步验证。

3.6 混频单因子检验结果

表 3.3 给出了最终展示的多样化前 10 个 GP 因子的单因子表现。最终展示因子的 Rank IC 集中在 0.0305–0.0347 区间，第 10 组与第 1 组收益差的年化值均为正。F03 的分层单调性略低于其他因子，但其表达式刻画交易笔数与大单卖压，和主动卖出波动、协方差、敏感性系数（beta）、收盘状态等结构差异较大，因此保留为高收益结构的代表。F07–F08 为混频表达式，F09–F10 为纯日频表达式，说明本文框架并非只检验分钟频因子；从全量样

本看，收益排序更靠前的表达式主要来自分钟微观结构信号。

表 3.3 最终展示的多样化前 10 个 GP 因子单因子表现

因子	频率	主要结构	Rank IC	第 10 组与第 1 组收益差年化值	分层单调性
F01	分钟	被动买量结构	0.0324	19.80%	0.891
F02	分钟	主动卖出变化波动	0.0344	13.73%	0.867
F03	分钟	交易活跃与大单卖压	0.0329	19.96%	0.818
F04	分钟	被动卖压与周转 beta	0.0332	14.20%	0.952
F05	分钟	主动卖出与波动协同	0.0324	12.28%	0.903
F06	分钟	波动小单与成交额状态	0.0307	17.85%	0.927
F07	混频	交易活跃与尾盘成交峰值	0.0347	14.08%	0.952
F08	混频	小单买入与日频超大单资金	0.0305	15.99%	0.976
F09	日频	开盘资金流与中单卖出	0.0315	15.94%	0.976
F10	日频	净流入动量与中单买入	0.0312	15.89%	0.976

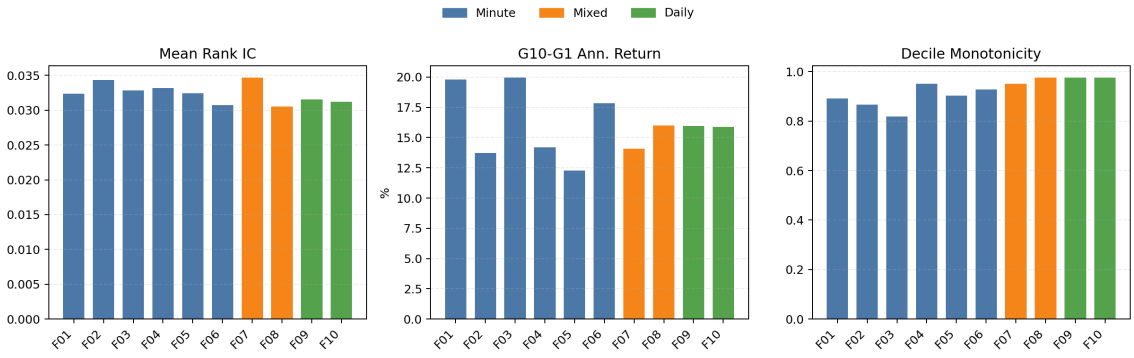


图 3.1 多样化前 10 个 GP 因子的 Rank IC、收益差与分层单调性

图 3.2 展示了每个因子的十分组年化收益。多数因子从低分组到高分组呈现递增结构，高分组整体优于低分组，说明这些表达式并非只在极少数股票上生效，而是在横截面排序意义下具有较稳定的信息含量。

分年度结果见图 3.3 与图 3.4。整体上，2021–2024 年的 Rank IC 与分组收益差表现较稳定；2025 年部分因子仍保持正 IC，但收益差有所回落，说明单因子 IC 与可交易组合收益之间并非完全等价，仍会受到市场风格、分组收益形态和交易成本的影响。

图 3.5、图 3.6 与图 3.7 分别给出代表性分钟、混频与日频因子的分层净值。高分组长期优于低分组，第 10 组与第 1 组的收益差净值整体向上，说明 GP 生成的公式因子在单因子层面具备可解释且可复核的横截面预测能力。

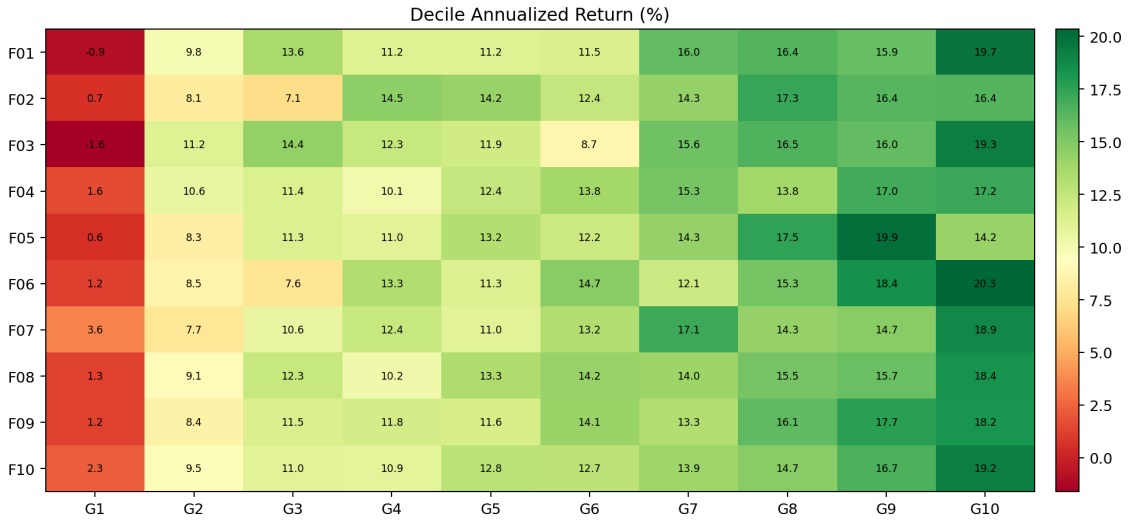


图 3.2 多样化前 10 个 GP 因子的十分组年化收益

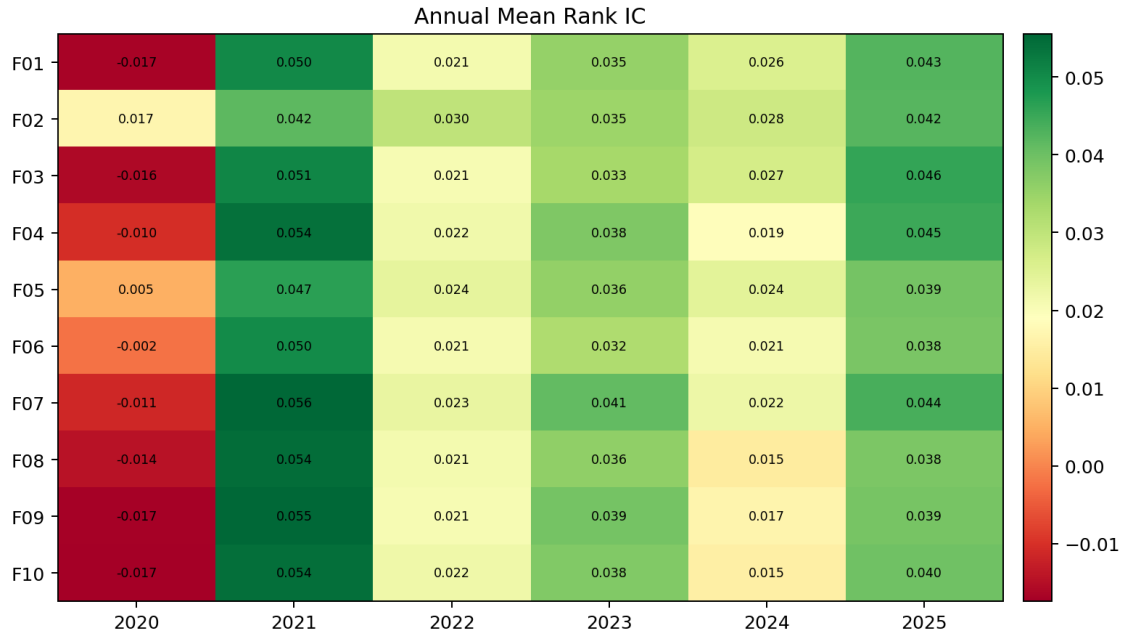


图 3.3 多样化前 10 个 GP 因子的分年度 Rank IC

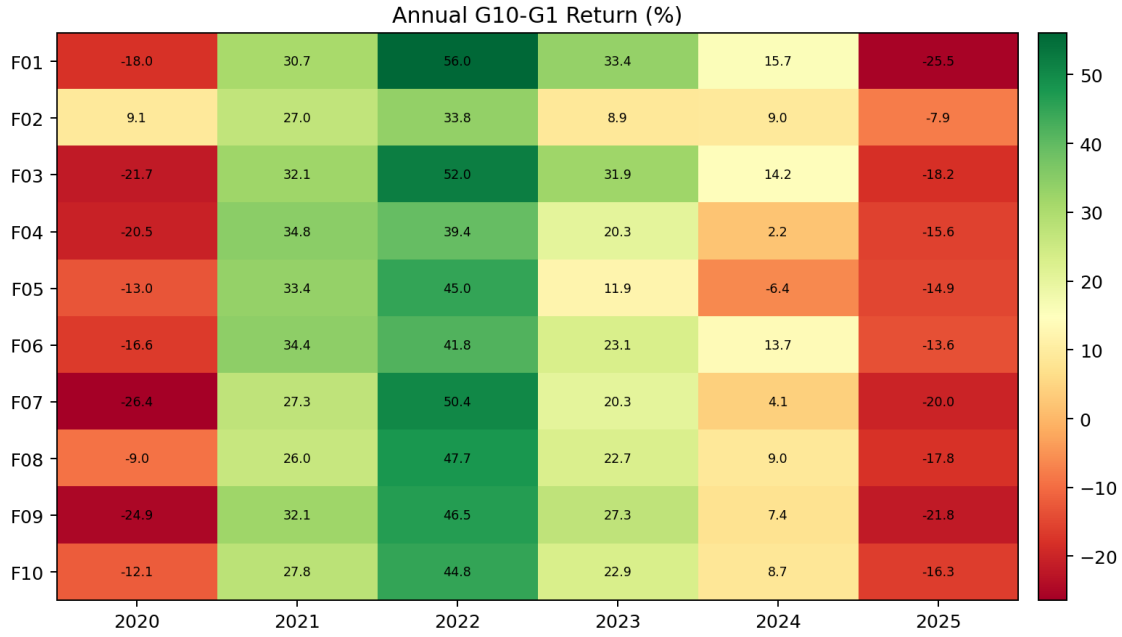


图 3.4 多样化前 10 个 GP 因子的分年度第 10 组与第 1 组收益差年化值

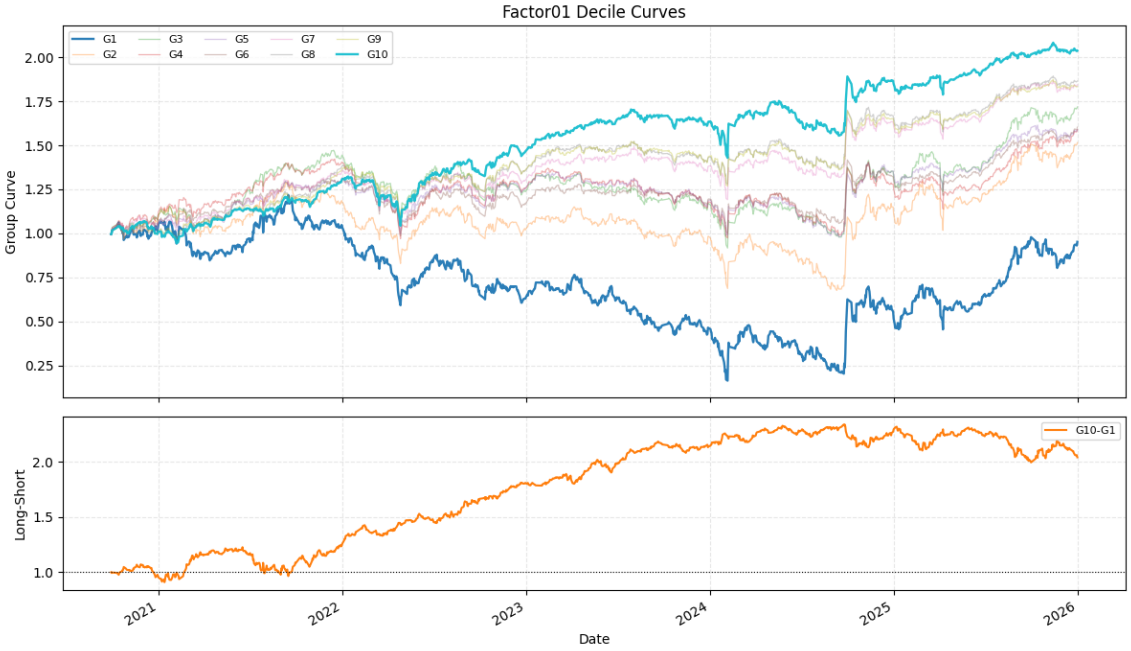


图 3.5 代表性分钟频因子 F01 的十分组净值与多空净值

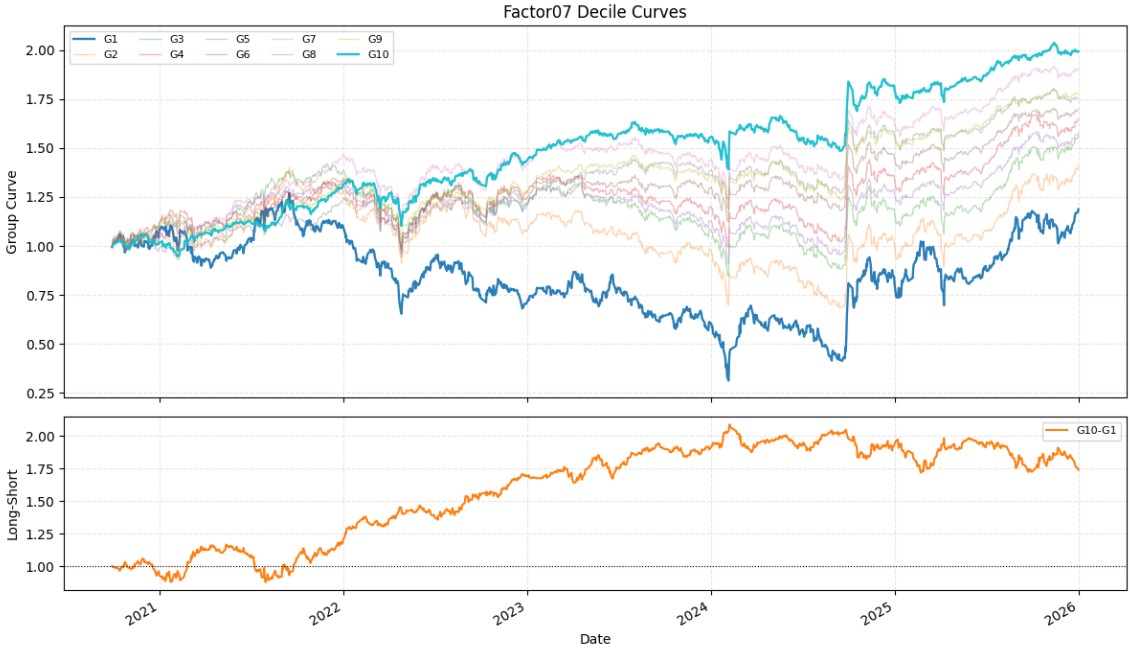


图 3.6 代表性混频因子 F07 的十分组净值与多空净值

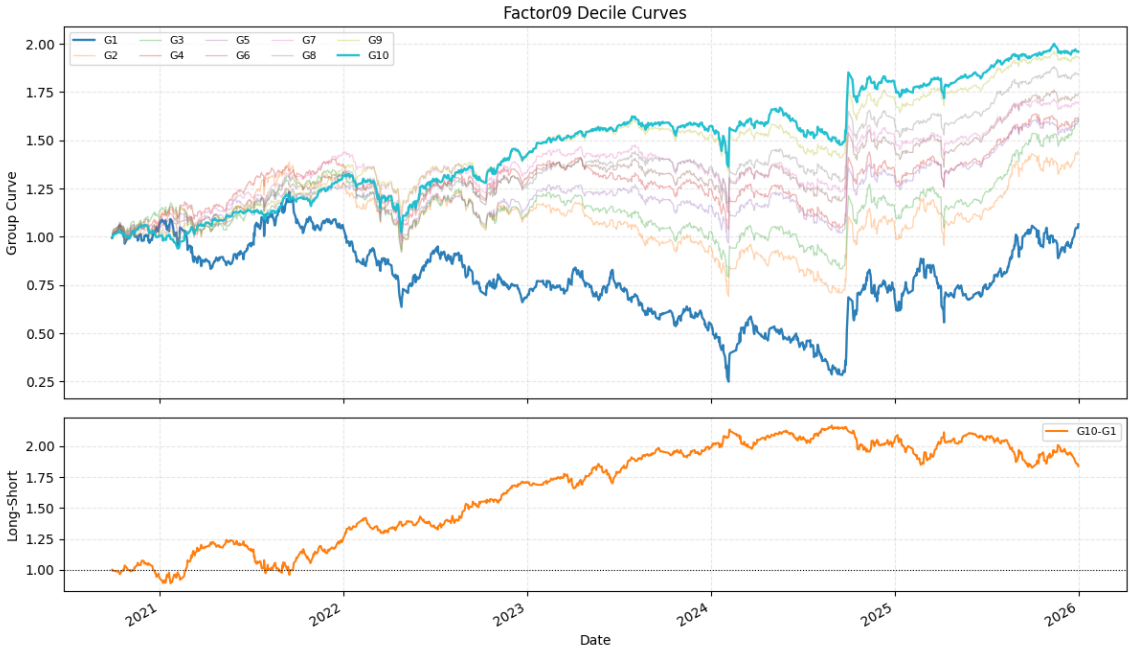


图 3.7 代表性日频因子 F09 的十分组净值与多空净值

3.6.1 前 10 个因子表达式展示

为保证可复现性，最终前 10 个因子的完整表达式如下所示。

代码 3.1: 前 10 个 GP 因子表达式

```
F01. mean_spread(sub(min_SmallPassiveBuyVolume, min_MedianPassiveBuyVolume), min_BigPassiveBuyDolvol)
F02. nanstd(diff(zscore(min_ActiveSellCount)))
F03. mean_spread(min_TradeCount,
    add(min(min_BigPassiveSellDolvol, min_BigPassiveSellDolvol), min_BigSellCount))
F04. am_beta(zscore(add(min_PassiveSellCount, min_MidTickTurnover)), min_MidTickTurnover)
F05. cov(zscore(min_ActiveSellCount), sub(min_Rvt, min_MedianPassiveBuyDolvol))
F06. last(sub(sub(min_Rvt, min_SmallPassiveBuyCount), min_Dolvol))
F07. d_sub(mean_spread(min_TradeCount,
    min(signedpower(min_BigActiveSellDolvol), signedpower(min_MidTickTurnover))),
    close30_mean(min_DolvolMax))
F08. d_sub(mean_spread(min_SmallBuyCount, add(min_DolvolMean, min_MidTickTurnover)),
    SELL_VALUE_EXLARGE_ORDER)
F09. d_sub(d_sub(OPEN_MONEYFLOW_PCT_VOLUME, SELL_VALUE_MED_ORDER_ACT), SELL_VALUE_MED_ORDER_ACT)
F10. d_sub(day_mean_10(NET_INFLOW_RATE_VOLUME), BUY_VALUE_MED_ORDER)
```

3.6.2 金融含义解释

最终前 10 个因子可归纳为四类机制。第一类是订单流不平衡与交易压力，例如 F01 和 F03 分别从被动买量与大单卖压角度刻画短期交易结构。第二类是波动、成交活跃度与微观结构动态，例如 F02、F04、F05 和 F06 分别利用主动卖单变化、被动卖压敏感性系数、协方差结构和收盘状态衡量交易摩擦。第三类是混频资金流结构，例如 F07 将分钟交易活跃度与尾盘成交峰值结合，F08 将分钟小单买入信号与日频超大单资金指标做差。第四类是纯日频资金流结构，F09 和 F10 分别刻画开盘资金流、中单卖出以及净流入动量与中单买入之间的关系。该展示集合既保留了分钟微观结构因子的预测能力，也纳入混频与日频表达式，从而降低对单一相似结构的依赖。

3.7 简单因子组合回测结果

在表 3.1 的配置下，表 3.4 给出了简单因子组合的样本外回测结果。前 5 个因子组合总收益较高，但因子集中度也更高；前 15 个因子组合收益略低，但 1 日 Rank IC 更高、最大回撤更小。因此，本文将“前 15 个 GP 因子 z-score 等权组合并持有 20 只股票”作为主回测设定。

表 3.4 中证 500 样本外主回测结果（截至 2025 年 12 月 31 日）

组合设定	总收益	年化收益	最大回撤	基准收益	超额收益	1 日 Rank IC
前 5 个因子 z-score 等权，持有 20 只	130.94%	24.89%	-22.57%	28.65%	102.29%	0.0317
前 15 个因子 z-score 等权，持有 20 只	103.95%	19.76%	-20.01%	28.65%	75.30%	0.0338

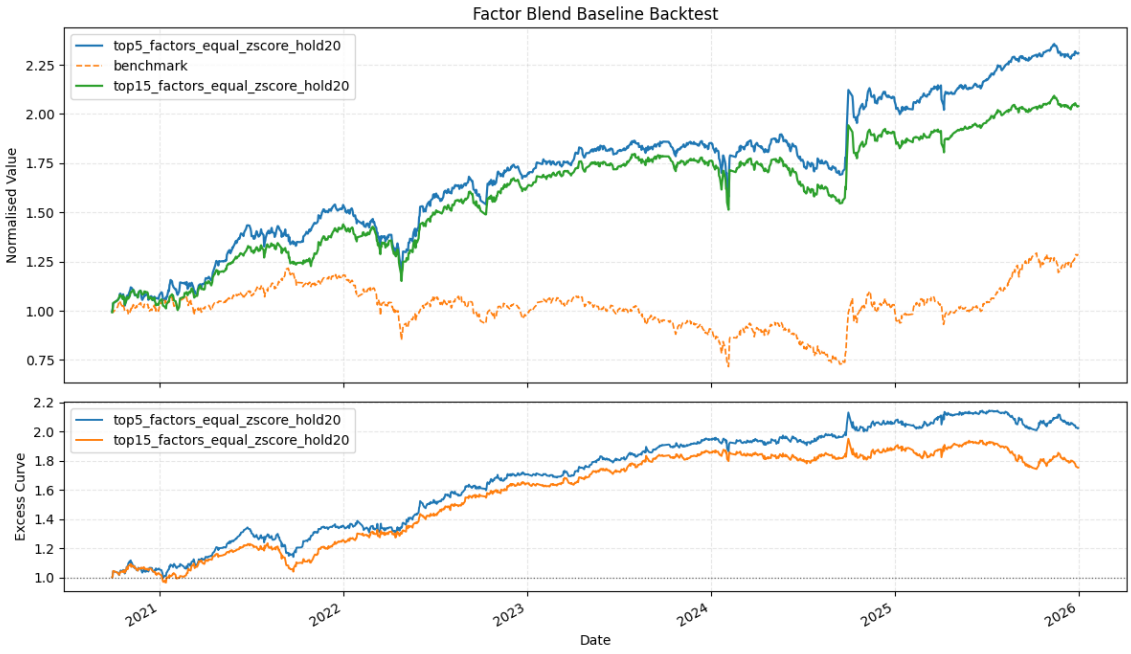


图 3.8 中证 500 样本外 GP 因子简单组合同口径回测结果

图 3.8 进一步展示了两种因子组合的净值曲线与相对中证 500 的超额净值。无论前 5 个还是前 15 个因子组合，在万三交易成本、5 日调仓和逐日记账条件下均跑赢基准，其中前 15 个因子组合曲线更平滑，回撤控制也更好。该结果表明，在不引入额外复杂预测模型的情况下，滚动 GA 因子经简单线性聚合后仍能形成具有经济意义的样本外预测信号。进一步地，就本文主结果这条策略本身而言，若对同一 2020-09-28 至 2025-12-31 样本外日度净收益序列改按复利累计，则累计收益为 151.38%，高于正文单利口径的 103.95%。因此，正文采用单利展示并未夸大收益，反而对这一版本的主策略结果给出了更保守的呈现。

3.8 下游模型的补充比较

为考察因子信息在不同信号合成模型中的转化效率，本文在同一套 GP 历史归档因子、同一固定列面板股票池和同一 `raw1d` 逐日记账口径下进行补充比较。实验统一使用万三交易成本和 5 日调仓设置，不重新运行 GP，只更换既有因子集合之上的合成方式。比较对象包括简单 z-score 等权组合、按历史因子 IC 线性加权、Ridge、ElasticNet、XGBoost 和固定快照 GRU。XGBoost 采用较保守的参数设定（`max_depth`=2、`learning_rate`=0.05、`n_estimators`=120、`subsample`=0.8、`colsample_bytree`=0.8），GRU 则沿用 4 段历史因子归档、18 个月训练窗、40 日输入序列和逐次调仓重训的方案。

表 3.5 简单因子组合与下游监督模型的补充比较

模型	5 日 Rank IC	1 日 Rank IC	总收益	最大回撤
前 15 个因子 z-score 等权	0.0316	0.0338	103.95%	-20.01%
前 15 个因子 IC 加权	0.0322	0.0341	98.05%	-19.54%
Ridge	0.0152	-0.0011	125.31%	-21.26%
ElasticNet	0.0153	0.0000	132.83%	-21.97%
XGBoost	0.0053	-0.0044	92.15%	-31.92%
GRU	0.0106	0.0064	78.15%	-36.36%

表 3.5 与图 3.9 表明，ElasticNet 在持有前 20 只股票的回测中的总收益最高，达到 132.83%，对应年化收益 25.25%。Ridge 的总收益也达到 125.31%。该结果说明，对既有 GP 因子施加受约束的线性组合，可能进一步放大头部选股收益。从曲线形态看，这两类线性模型在多数年份都能维持向上的累计净值，但相对简单 z-score 组合并未显著改善回撤特征。这一现象与因子定价文献中“上游特征已包含较强结构信息时，下游低自由度模型往往更易保持稳健性”的经验观察相一致[13-14]。

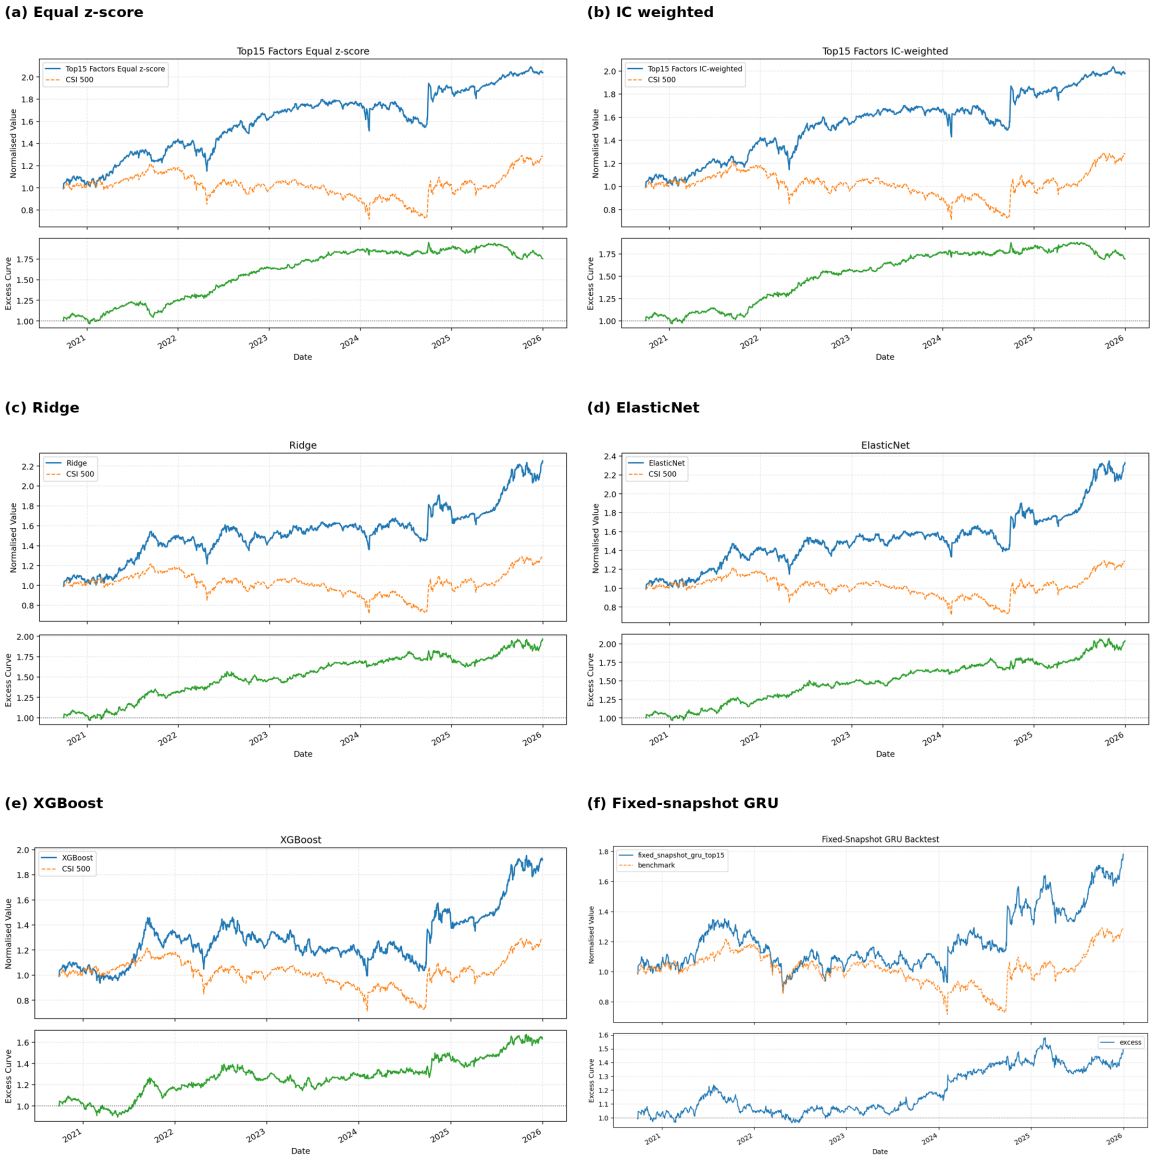


图 3.9 不同信号合成模型的回测净值与超额曲线分面图

若同时考察整体排序能力，线性监督模型的优势并不稳定。ElasticNet 的 5 日 Rank IC 为 0.0153，1 日 Rank IC 约为 0；Ridge 的 1 日 Rank IC 转负。相比之下，简单 z-score 等权组合和 IC 加权组合的 1 日 Rank IC 稳定在 0.034 左右。GRU 和 XGBoost 的结果则更差。

但值得肯定的是，在简单 z-score 组合超额收益为负的 2025 年，ElasticNet、Ridge 和 XGBoost 发挥出色。在牛市之中，它们似乎能更好地把握住头部收益。

相比于形成稳定的全截面排序优势，复杂模型更擅长在部分年份捕捉到头部收益机会。进一步结合早期日频简单因子的结果，可以推测：当上游已经提供较复杂的时序因子结构时，下游继续叠加时序模型未必能够稳定增益；时序模型的潜在价值，可能更多体现在识别因子信号随市场状态变化而衰减或切换的过程，而非对既有 GP 因子再做一轮更复杂的静态横截面排序。这一结论与“基础特征配复杂时序模型”和“复杂特征配较简单下游模型”在不同文献中分别成立的经验事实是一致的[3-4,15-16]。

4 结论与展望

4.1 研究结论

本文以股票收益预测为实验载体，围绕时序预测问题中的因子挖掘模拟方法开展研究，并最终形成一套混合频率强类型遗传编程框架。研究结果表明，早期仅含日频信息的阶段性模型在统一 raw1d 记账口径下仍能取得正向超额收益，说明“因子挖掘 + 时序信号构造”的研究路径在方法上具有可行性。进一步地，在分钟频与日频联合输入条件下，类型受约束的函数库能够有效排除非法表达式组合，提高演化搜索效率，并使跨频率表达式的构造过程更可控、更可解释。同时，以 Rank IC 为核心、结合 IC 阈值、分层单调性和相似度约束的筛选机制，能够在控制冗余的同时保留有效表达式。基于该框架挖掘的公式化因子在固定中证 500 股票池上表现出正向 Rank IC 与分层收益，进一步采用滚动更新的因子集合、横截面 z-score 标准化和等权组合后，能够形成具有经济意义的样本外预测信号。

总体而言，本文方法在有限算力条件下兼顾了可解释性、有效性与工程实现可行性。研究路径上，早期日频探索说明“因子挖掘后再接时序模型”具有潜在价值，但相邻版本之间结果波动较大，稳健性不足；正文主结果则表明，混合频率 GP 挖掘得到的因子经过简单 z-score 等权组合，已经能够形成稳定的样本外预测信号。补充实验显示，ElasticNet 一类受约束的线性模型能够进一步提高持有 20 只股票组合的净值，但其整体 Rank IC 弱于简单等权组合。

4.2 不足与未来工作

尽管取得阶段性结果，本文仍存在若干不足。首先，搜索空间与超参数规模较大，训练成本仍然偏高；其次，当前实验主要在单市场样本上验证，跨市场和跨周期的泛化能力仍需进一步检验；再次，正文主回测采用简单 z-score 等权组合，补充实验覆盖的后续信号合成模型仍较有限。

后续工作可沿三个方向继续展开。在保持强类型约束的前提下，还可以继续优化搜索空间与超参数设置，以降低训练成本并提升有效表达式的发现效率；也可以在跨市场、跨年份与不同风格环境下开展更系统的滚动样本外检验，以验证混合频率 GP 因子的泛化能

力；此外，还需要进一步研究“因子复杂度 - 下游模型复杂度”的匹配关系，分别评估复杂因子配简单模型、简单因子配时序模型两条路线的适用边界。

5 参考文献

[1] FAMA E F, FRENCH K R. Common Risk Factors in the Returns on Stocks and Bonds[J/OL]. Journal of Financial Economics, 1993, 33(1): 3-56. https://doi.org/10.1016/0304-405X(93)90023-5. DOI: 10.1016/0304-405X(93)90023-5.

[2] CARHART M M. On Persistence in Mutual Fund Performance[J/OL]. The Journal of Finance, 1997, 52(1): 57-82. https://doi.org/10.1111/j.1540-6261.1997.tb03808.x. DOI: 10.1111/j.1540-6261.1997.tb03808.x.

[3] GU S, KELLY B, XIU D. Empirical Asset Pricing via Machine Learning[J/OL]. The Review of Financial Studies, 2020, 33(5): 2223-2273. https://doi.org/10.1093/rfs/hhaa009. DOI: 10.1093/rfs/hhaa009.

[4] FISCHER T, KRAUSS C. Deep Learning with Long Short-Term Memory Networks for Financial Market Predictions[J/OL]. European Journal of Operational Research, 2018, 270(2): 654-669. https://doi.org/10.1016/j.ejor.2018.04.048. DOI: 10.1016/j.ejor.2018.04.048.

[5] SHI H, SONG W, ZHANG X, et al. AlphaForge: A Framework to Mine and Dynamically Combine Formulaic Alpha Factors[EB/OL]. 2024 [2026-04-30]. https://arxiv.org/abs/2406.18394. arXiv: 2406.18394.

[6] ALLEN F, KARJALAINEN R. Using Genetic Algorithms to Find Technical Trading Rules[J/OL]. Journal of Financial Economics, 1999, 51(2): 245-271. https://doi.org/10.1016/S0304-405X(98)00052-X. DOI: 10.1016/S0304-405X(98)00052-X.

[7] ZHANG T, LI Y, JIN Y, et al. AutoAlpha: An Efficient Hierarchical Evolutionary Algorithm for Mining Alpha Factors in Quantitative Investment[EB/OL]. 2020 [2026-04-30]. https://arxiv.org/abs/2002.08245. arXiv: 2002.08245.

[8] REN W, QIN Y, LI Y. Alpha Mining and Enhancing via Warm Start Genetic Programming for Quantitative Investment[EB/OL]. 2024 [2026-04-30]. https://arxiv.org/abs/2412.00896. arXiv: 2412.00896.

[9] ZOU H, HASTIE T. Regularization and Variable Selection via the Elastic Net[J/OL]. Journal of the Royal Statistical Society: Series B (Statistical Methodology), 2005, 67(2): 301-320. https://doi.org/10.1111/j.1467-9868.2005.00503.x. DOI: 10.1111/j.1467-9868.2005.00503.x.

[10] CHEN T, GUESTRIN C. XGBoost: A Scalable Tree Boosting System[C/OL]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016: 785-794. https://doi.org/10.1145/2939672.2939785. DOI: 10.1145/2939672.2939785.

[11] KRAUSS C, DO X, HUCK N. Deep Neural Networks, Gradient-Boosted Trees, and Random Forests: A Systematic Comparison for Stock Market Prediction[J/OL]. European Journal of Operational Research, 2017, 259(2): 689-702. https://doi.org/10.1016/j.ejor.2017.10.032. DOI: 10.1016/j.ejor.2017.10.032.

[12] CHO K, van MERRIENBOER B, GULCEHRE C, et al. Learning Phrase Representations Using RNN Encoder–Decoder for Statistical Machine Translation[C/OL]//Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2014: 1724-1734. https://doi.org/10.3115/v1/D14-1179. DOI: 10.3115/v1/D14-1179.

[13] KELLY B T, PRUITT S, SU Y. Characteristics Are Covariances: A Unified Model of Risk and Return [J/OL]. Journal of Financial Economics, 2019, 134(3): 501-524. https://doi.org/10.1016/j.jfineco.2019.05.001. DOI: 10.1016/j.jfineco.2019.05.001.

[14] FREYBERGER J, NEUHIERL A, WEBER M. Dissecting Characteristics Nonparametrically[J/OL]. The Review of Financial Studies, 2020, 33(5): 2326-2377. https://doi.org/10.1093/rfs/hhz123. DOI: 10.1093/rfs/hhz123.

[15] FENG G, HE J, POLSON N G, et al. Deep Learning in Characteristics-Sorted Factor Models[J/OL]. Journal of Financial and Quantitative Analysis, 2024, 59(7): 3001-3036. https://doi.org/10.1017/S0022109023000893. DOI: 10.1017/S0022109023000893.

[16] DIDISHEIM A, KE S, KELLY B T, et al. Complexity in Factor Pricing Models: 31689[R/OL]. National Bureau of Economic Research. 2023. https://doi.org/10.3386/w31689.

[17] WANG S, YUAN H, ZHOU L, et al. Alpha-GPT: Human-AI Interactive Alpha Mining for Quantitative Investment[EB/OL]. 2023 [2026-04-30]. https://arxiv.org/abs/2308.00016. arXiv: 2308.00016.

[18] HOLLAND J H. Adaptation in Natural and Artificial Systems[M]. Ann Arbor: University of Michigan Press, 1975.

[19] KOZA J R. Genetic Programming: On the Programming of Computers by Means of Natural Selection [M]. Cambridge, MA: MIT Press, 1992.
[20] POLI R, LANGDON W B, MCPHEE N F. A Field Guide to Genetic Programming[M/OL]. Lulu Press, 2008. http://www.gp-field-guide.org.uk.
[21] MAKKE N, CHAWLA S. Interpretable Scientific Discovery with Symbolic Regression: A Review [J/OL]. Artificial Intelligence Review, 2024, 57. https://doi.org/10.1007/s10462-023-10622-0. DOI: 10.1007/s10462-023-10622-0.
[22] DONG J, ZHONG J. Recent Advances in Symbolic Regression[J/OL]. ACM Computing Surveys, 2025, 57(11). https://doi.org/10.1145/3735634. DOI: 10.1145/3735634.
[23] 曹春晓, 郭樾. 基于 Dask 计算图的遗传规划高频因子挖掘框架: 机器学习选股系列研究之二[R]. 方正证券研究所, 2026.
[24] 中证指数有限公司. 中证 200、中证 500、中证 700 和中证 800 指数编制方案[EB/OL]. V1.2. 2022 [2026-05-06]. https://oss-ch.csindex.com.cn/static/html/csindex/public/uploads/indices/detail/files/zh_CN/000905_Index_Methodology_cn.pdf.

作者简历

姓名：郭景行　性别：男　民族：汉

出生年月：2004-09-18　籍贯：浙江省诸暨市

2019.09–2022.07　浙江省诸暨中学

2022.09–2026.07　浙江大学攻读学士学位

获奖情况：

参加项目：

发表的学术论文：Guo J, Luo X, Yang L. Intraday herding drivers in China’s A-share market: evidence from the China Securities Smallcap 500 Index[J]. Finance Research Letters, 2025, 85(Part E): 108292. DOI: 10.1016/j.frl.2025.108292.（第一作者）

本科生毕业论文（设计）任务书

一、题目：

二、指导教师对毕业论文（设计）的进度安排及任务要求：

起讫日期 20　年　月　日　至　20　年　月　日

指导教师（签名）_____ 职称 _____

三、系或研究所审核意见：

负责人（签名）_____

年　月　日

本科生毕业论文（设计）考核

一、指导教师对毕业论文（设计）的评语：

指导教师（签名）_____

年　月　日

二、答辩小组对毕业论文（设计）的答辩评语及总评成绩：

成绩比例	文献综述（10%）	开题报告（15%）	外文翻译（5%）	毕业论文质量及答辩（70%）	总评成绩
分值					

负责人（签名）_____

年　月　日

第二部分

毕业论文开题报告

浙 江 大 學

本 科 生 毕 业 论 文

文献综述和开题报告



姓名与学号	郭景行 3220102983
指导教师	胡贤良
年级与专业	2022级统计学
所在学院	数学科学学院

一、题目：时序预测问题因子挖掘的模拟方法

二、指导教师对文献综述、开题报告、外文翻译的具体要求：

指导教师（签名）_____

年　月　日

一、文献综述

1 背景介绍

本节综述自动化因子挖掘与基于深度学习的收益预测在量化选股中的研究进展，聚焦遗传算法/遗传规划（GA/GP）用于因子生成的方法与将因子作为神经网络输入的混合建模思路。

1.1 自动化因子挖掘

近年来，针对海量候选表达式空间，研究者提出采用进化算法（GA/GP）自动化生成 Alpha 因子以发现新的预测信号。代表性工作包括[1] 中提出的 AutoAlpha 框架，它通过分层进化与多样性控制在大规模搜索空间中高效生成高质量因子；以及[2] 提出的 Warm-Start GP 方法，通过以已有有效结构为种子初始化种群，从而提高搜索效率与结果稳定性。近年还出现如 AlphaForge、Alpha-GPT 等面向工程化与人机交互的因子挖掘框架，强调因子组合与动态更新策略[3-4]。

这类方法的共性在于：将表达式编码为可演化个体、设计基于截面信息系数（IC）及其稳健性指标的适应度函数，并引入相关性惩罚或多样性正则以抑制同质化。已有研究显示，采用分层/种子机制能降低早熟收敛并提升样本外表现。

1.2 基于深度学习的收益预测

门控循环单元（GRU）作为高效的序列模型，在金融时间序列预测中被广泛应用（参见 GRU 原始工作[5]）。在深度学习与机器学习方法的对比研究中，LSTM/GRU 与树模型、集成方法的效果被系统评估（参见[6-7]）；近期工作也比较了 LSTM、GRU 与 Transformer 在价格预测任务中的性能差异[8]。此外，部分研究将序列模型与因子预测任务结合，探索基于序列预测的选股方法[9]。

1.3 因子挖掘与神经网络融合

将自动化挖掘的因子作为神经网络输入，结合进化算法与深度学习的优势，已成为一个有前景的研究方向（参见[1-4]）。现有工作多在两阶段流水线实现：先用 GA/GP 挖掘表达式，再将表达式在原始因子数据上求值作为特征输入模型进行训练与回测。关键挑战包括因子时效性、过拟合（深度模型示例见[7]）与因子间相关性控制。

1.4 存在的问题与研究空间

虽然已有研究取得一定成果，但仍存在若干问题：

- 因子结构的可解释性与稳定性不足；
- 如何在演化过程直接优化模型端性能（端到端联动）尚未充分研究；
- 多因子池在实盘下的组合构建、调仓成本与滑点敏感性需进一步验证。

2 研究展望

基于上述分析，本研究将：一是沿用并改进 Warm-Start 与多样性正则机制以提高因子挖掘效率；二是研究如何将 GA 生成因子更有效地与 GRU 模型融合（例如特征选择、正则化与联合验证策略）；三是建立严格的样本外滚动回测框架以检验方法的稳健性。

3 国内外研究现状

3.1 研究方向及进展

国内外在自动化因子挖掘与因子＋模型混合的研究呈现出以下趋势：

- 从单一适应度向多目标适应度转变：研究者开始在适应度中同时考察信息量（IC）、稳定性（ICIR）与交易成本指标；
- 引入种子与分层机制以提升搜索效率：Warm-Start 与 AutoAlpha 的分层/种子策略能够在保证多样性的同时聚焦高质量区域；

- 模型联动与混合方法增多：越来越多工作将演化搜索与神经网络/树模型结合，用于提升截面排序能力或作为特征筛选步骤。

3.2 存在问题

目前尚存的问题包括：

- 大量工作停留在两阶段流水线，缺乏以最终投资绩效为目标的端到端优化；
- 因子时效性导致实际应用中频繁失效，缺乏长期稳定性评估的通用方案；
- 回测中交易摩擦、滑点与资金容量经常被简化处理，影响结果的可应用性。

4 研究展望

基于前文的综述与存在问题，本研究的后续研究方向与具体技术路线包括以下几点：

1. 端到端联合优化：探索将模型端性能（如样本外回测净值或预测误差）纳入适应度函数的可行方案，设计可微或可替代的性能代理指标，使进化搜索不仅优化表达式的截面统计指标（IC），也能反映模型端的最终目标，从而缩短因子到策略间的目标差距。

2. 因子稳定性与多样性增强：在 Warm-Start 的基础上，引入多种种子来源（不同时间窗/市场/行业），并在适应度中加入跨期稳定性惩罚（例如跨滚动窗口的 IC 波动率或 ICIR），同时使用多样性约束（相关性惩罚或基于主成分的多样性度量）降低因子同质化风险。

3. 实盘约束与交易摩擦建模：在回测流程中纳入更真实的交易成本模型（滑点、佣金、冲击成本）、资金约束与最小交易单位，评估策略在不同成交量假设下的可实现性，保证回测结果更接近实盘表现。

4. 严格的滚动样本外验证：采用滚动训练-验证-测试方案，并通过时间序列交叉验证、行列交叉验证与对抗验证（adversarial validation）检测样本外偏差，确保发现的因子与模型在未知数据上的鲁棒性。

5. 模型与算法的混合与集成：研究将演化挖掘得到的因子与深度学习（GRU、Transformer）、树模型（XGBoost）进行融合或级联，探索堆叠式/集成式策略以提升预测稳定性；同时研究特征选择与稀疏正则化以减少模型复杂度。

6. 可解释性与简化表达式：对演化得到的复杂表达式进行符号简化与可解释性分析（如用 SHAP、LIME 或符号推导工具），筛选表达式中经济学合理且可解释的子结构，便于风险审查与合规需求。

7. 多市场与跨周期验证：在中证 500 与沪深 300 之外，拓展到其他市场或行业子集，检验方法的普适性及对市场结构变化的敏感性；进行跨周期（牛熊市）性能分解以评估策略在不同市场环境下的表现。

8. 部署与监控：构建一套可重复的工程化流水线（数据获取 → 因子挖掘 → 因子求值 → 模型训练 → 回测 → 报告），并设计在线监控指标（IC 滚动均值、IC 波动、持仓集中度等）用于实盘监控与策略退市触发。

9. 探索新模型架构：评估 Transformer、Temporal Convolutional Networks 等在金融序列上的表现，与 GRU 比较在特征提取与长期依赖建模方面的优劣。

通过以上方向的系统研究与工程实现，本研究目标不仅限于学术发表，更着眼于构建工程化、可实盘的选股框架，实现长期稳健的超额收益与风险可控的策略。

5 参考文献

[1] ZHANG T, LI Y, JIN Y, et al. AutoAlpha: An Efficient Hierarchical Evolutionary Algorithm for Mining Alpha Factors in Quantitative Investment[EB/OL]. 2020 [2026-04-30]. https://arxiv.org/abs/2002.08245. arXiv: 2002.08245.

[2] REN W, QIN Y, LI Y. Alpha Mining and Enhancing via Warm Start Genetic Programming for Quantitative Investment[EB/OL]. 2024 [2026-04-30]. https://arxiv.org/abs/2412.00896. arXiv: 2412.00896.

[3] SHI H, SONG W, ZHANG X, et al. AlphaForge: A Framework to Mine and Dynamically Combine Formulaic Alpha Factors[EB/OL]. 2024 [2026-04-30]. https://arxiv.org/abs/2406.18394. arXiv: 2406.18394.

[4] WANG S, YUAN H, ZHOU L, et al. Alpha-GPT: Human-AI Interactive Alpha Mining for Quantitative Investment[EB/OL]. 2023 [2026-04-30]. https://arxiv.org/abs/2308.00016. arXiv: 2308.00016.

[5] CHO K, van MERRIENBOER B, GULCEHRE C, et al. Learning Phrase Representations Using RNN Encoder–Decoder for Statistical Machine Translation[C/OL]//Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2014: 1724-1734. https://doi.org/10.3115/v1/D14-1179. DOI: 10.3115/v1/D14-1179.

[6] KRAUSS C, DO X, HUCK N. Deep Neural Networks, Gradient-Boosted Trees, and Random Forests: A Systematic Comparison for Stock Market Prediction[J/OL]. European Journal of Operational Research, 2017, 259(2): 689-702. https://doi.org/10.1016/j.ejor.2017.10.032. DOI: 10.1016/j.ejor.2017.10.032.

[7] FISCHER T, KRAUSS C. Deep Learning with Long Short-Term Memory Networks for Financial Market Predictions[J/OL]. European Journal of Operational Research, 2018, 270(2): 654-669. https://doi.org/10.1016/j.ejor.2018.04.048. DOI: 10.1016/j.ejor.2018.04.048.

[8] XIAO J, DENG T, BI S. Comparative Analysis of LSTM, GRU, and Transformer Models for Stock Price Prediction[EB/OL]. 2024 [2026-04-30]. https://arxiv.org/abs/2411.05790. arXiv: 2411.05790.

[9] SUN J. A Stock Selection Method Based on Earning Yield Forecast Using Sequence Prediction Models [EB/OL]. 2019 [2026-04-30]. https://arxiv.org/abs/1905.04842. arXiv: 1905.04842.

二、开题报告

1 问题提出的背景

本节说明研究问题的提出背景、项目缘由以及本研究拟达到的目标与意义。

1.1 背景介绍

随着数据可得性和计算资源的提升，量化投资中使用自动化方法挖掘 Alpha 因子成为主流趋势。近年来，基于遗传算法/遗传规划（GA/GP）的表达式搜索方法被广泛用于自动构建候选因子集合（参见[1-2]），而深度学习模型（如 GRU）在时间序列预测中表现出较强的建模能力（参见[3]）。将自动化因子挖掘与序列模型相结合，能够同时兼顾因子的可解释性与模型的非线性建模能力，从而在选股策略中探索新的超额收益来源。

1.1.1 项目提出的原因

简而言之，当前大量自动化因子挖掘的研究与工程化实现，最终目标之一是实现可持续的投资收益——”赚钱”是很现实且核心的动机。现有方法在搜索效率、因子稳定性与样本外可复现性方面仍存在不足：一方面，未经约束的搜索容易产生短期有效但易失效的“爆款”因子；另一方面，回测常常简化交易摩擦和资金约束，导致实盘适用性不足。因此，本项目提出结合 Warm-Start/分层进化与 GRU 预测的混合框架，旨在提高因子发现的效率与长期稳健性。

1.2 本研究的意义和目的

本研究的目标包括学术与实践两方面：

- 学术意义：在方法层面改进自动化因子挖掘流程，引入结构化种子（Warm-Start）与多目标适应度（信息量与稳定性），并研究如何将挖掘到的因子更有效地与时间序列模型（GRU）融合，以提升模型的截面排序能力与时间依赖建模能力；

- 实践意义：构建一套可复现的端到端工程流程（因子挖掘 → 因子求值 → 特征构建 → GRU 训练 → 严格滚动回测），在尽量模拟实盘条件下验证策略性能，目标是在中证 500 与沪深 300 等主要指数上实现稳健的超额收益并控制回撤。

本研究的直接预期是优化回测流程、提高因子与模型的样本外稳健性，并为后续实盘化提供可行性分析与工程实现建议。

2 项目的主要内容和技术路线

2.1 主要研究内容

本项目提出并实现一种“GA 因子生成 + GRU 收益预测”的端到端量化选股框架。主要研究内容包括：

1. 基于遗传算法/遗传规划（GA/GP）自动化生成 Alpha 因子，设计多种适应度函数（Mean Abs IC、ICIR、AMIC）并引入多样性惩罚以避免因子同质化；

2. 提出并实现 warm-start 机制，从已有有效因子结构出发加速搜索，提高挖掘效率和稳定性；

3. 将 GA 生成的因子在原始因子数据上求值后作为特征输入门控循环单元（GRU）神经网络，构建用于股票未来收益预测的”GA-GRU” 混合模型；

4. 设计滚动回测框架验证策略有效性，输出累计收益、年化收益、波动率、最大回撤和夏普比率等绩效指标，并完成可复现的实验流程与报告。

以上内容将分别在方法设计、模型训练与回测三个子模块中实现与验证。

2.2 技术路线

本研究的技术路线可概括为三步：数据与因子构建 → 因子挖掘 → GRU 预测与回测。

1) 数据预处理与因子字典 收集价格与因子基础字段（如 close_adj、pct_chg、turn、pe_ttm 等），完成缺失值处理、对齐和标准化，构建用于表达式求值的因子字典与标签（未来 k 日收益）。

2) 基于 GA/GP 的因子挖掘 使用遗传算法将因子表达式编码为个体，通过选择、交叉与变异搜索表达式空间。适应度函数包括：

- Mean Absolute IC（信息量）
- ICIR（收益风险比）
- Absolute Mean IC（累积方向性）

同时在适应度中加入与已入池因子的相关性惩罚，保证多样性。引入 warm-start 机制以 seed 表达式作为种群初始化，从而提高收敛稳定性。

3) 因子求值与特征构建 将 GA 输出的表达式在历史因子数据上逐条求值，生成形状为（日期 × 股票 × 表达式）的 3D 特征张量，作为 GRU 的输入。必要时对表达式结果做 winsorize 与归一化处理。

4) GRU 模型训练与预测 构建多层 GRU 模型（可选 Dropout 与 Batch Normalization），使用 Adam 优化并配合早停策略训练。模型输出为每只股票未来 *predict_days* 日的收益预测值，用于截面排序与选股。

5) 滚动回测与评价 采用滚动训练-预测-调仓的回测框架（参数包括初始训练月数、最小训练样本数与调仓周期），在每次调仓可选触发 GA 更新表达式并重训练 GRU。评价指标包括累计收益、年化收益、年化波动、最大回撤和夏普比率，回测结果输出为 CSV、JSON 与图表以便分析。

2.3 可行性分析

数据与资源可行性 研究所需的历史价格与因子字段已在数据源中可得（见第 3.1 节），并有充足样本用于训练与回测；实现环境可采用本地 XeLaTeX 编译和 Python 科学计算栈

（numpy、pandas、torch/keras、xgboost 等）。

方法可行性 遗传算法与遗传规划在自动化表达式搜索方面已有成熟工作（如 AutoAlpha、Warm-Start GP），GRU 在时间序列预测中的有效性也被大量文献证明，二者结合具有明确的理论与实践依据。

工程实现可行性 本项目已在代码仓（src/pipelines）构建模块化实现的初始骨架（包括 ga_factor_miner.py、gru_forecaster.py 与 gru_backtester.py），便于实现、调参与复现实验。

风险与应对 主要风险包括过拟合与因子时效性问题。应对措施为：引入早停与正则化、在因子适应度中考虑稳定性指标（ICIR）并进行样本外验证，使用多因子池降低单因子失效风险。

本节将作为开题报告中“项目的主要内容和技术路线”的主体部分，后续可根据导师与评审意见进一步补充实验计划与时间表。

3 研究计划进度安排及预期目标

3.1 进度安排

本研究需在 5 月前完成初稿并提交，故将原计划压缩为三大阶段：

1. 阶段一（当前—3 月末）：数据准备与基础框架搭建。完成历史价格与因子字段的清洗、对齐与缺失值处理；进行初步探索性分析；搭建回测框架最小可运行版本；实现 GA/GP 管道的基本骨架以便快速迭代与调试。

2. 阶段二（4 月）：因子挖掘与模型训练。集中实现分层/种子（Warm-Start）策略并测试不同适应度（Mean Abs IC、ICIR、AMIC）；对候选表达式进行求值、构建特征张量并训练 GRU 模型，开展快速交叉验证与早停；进行初步样本外回测以筛选候选策略。

3. 阶段三（5 月）：严格回测、参数优化与初稿撰写。构建滚动样本外回测（纳入交易摩擦、滑点与资金容量约束），优化调仓周期与组合构建规则；完成性能稳健性与敏

感性分析；撰写并提交初稿（含方法、实验与参考文献）。

3.2 预期目标

当前进度：仍在优化回测与参数选择（包括调仓周期、交易成本假设与样本切分），但所有任务均按压缩日程优先推进。

主要预期目标（需在 5 月前完成并在初稿中呈现）：

- 在中证 500 与沪深 300 上实现稳健的超额收益（相对基准持续正 alpha）；
- 将最大回撤控制在可接受范围内（目标示例：单次回撤低于 15%）；
- 输出完整且可复现的工程化流水线，并提交若干可解释的因子表达式以便后续研究或实盘测试；
- 完成并提交含方法、实验与结果分析的初稿。

为保证结果可靠性，回测将优先采用严格的滚动样本外验证，并在回测中尽量模拟交易摩擦与资金约束。

4 参考文献

[1] ZHANG T, LI Y, JIN Y, et al. AutoAlpha: An Efficient Hierarchical Evolutionary Algorithm for Mining Alpha Factors in Quantitative Investment[EB/OL]. 2020 [2026-04-30]. https://arxiv.org/abs/2002.08245. arXiv: 2002.08245.

[2] REN W, QIN Y, LI Y. Alpha Mining and Enhancing via Warm Start Genetic Programming for Quantitative Investment[EB/OL]. 2024 [2026-04-30]. https://arxiv.org/abs/2412.00896. arXiv: 2412.00896.

[3] CHO K, van MERRIENBOER B, GULCEHRE C, et al. Learning Phrase Representations Using RNN Encoder–Decoder for Statistical Machine Translation[C/OL]//Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2014: 1724-1734. https://doi.org/10.3115/v1/D14-1179. DOI: 10.3115/v1/D14-1179.

三、外文翻译

1 摘要译文

传统的遗传编程（GP）在股票 Alpha 因子发现中常常面临挑战，原因在于其巨大的搜索空间、沉重的计算负担以及有效 Alpha 的稀疏性。我们发现，当 GP 专注于有前景的区域而非随机搜索时，其表现更佳。本文提出了一种新的遗传编程框架，该框架通过精心选择的初始化和结构性约束来增强搜索性能并提高 Alpha 因子的可解释性。此方法的动机源于对 Alpha 搜索实践的模仿，旨在提升此类过程的效率。对 2020 年至 2024 年中国股市数据的分析表明，我们的方法在样本外预测结果和投资组合收益方面均优于基准。

2 方法译文

我们的框架提供了一个强有力的起始点，并通过限制搜索空间来提升效率。其核心思想源于对有效 Alpha 因子结构的观察：一个因子的有效性不仅来源于其变量和函数，也根植于其内在结构。我们提出了两个核心假设：假设 1，一个有效的 Alpha 结构能提高发现有效 Alpha 的可能性；假设 2，一个有效的 Alpha 通常具备一个有效的结构，因此投资者可以通过选取一个已被验证有效的 Alpha，并将其结构作为有效的搜索空间。

基于此，我们提出了“暖启动遗传编程”（Warm Start GP）框架。与传统 GP 随机生成初始种群不同，该框架从一个单独的有效 Alpha 个体（根据假设 2 选取）开始搜索。这个初始个体不仅提供了一个良好的搜索起点，也定义了一个有效的树形结构。在搜索过程中，框架通过设计“受限交叉算子”（Restricted Crossover Operator），只允许拥有相同结构的个体在相同位置交换子树，并结合点突变，确保所有搜索操作都在初始个体所定义的结构内进行，从而保证子代 Alpha 的结构不变。这样，搜索就被限制在一个围绕有效起始点的、更有希望的小空间内，既加速了收敛，也增强了结果的可解释性。

3 实验与结论译文

我们在中国 A 股市场上进行了实验，将所提出的暖启动 GP 框架与传统的 GP 以及原始的 Alpha101 因子进行了比较。因子挖掘期为 2020 年 1 月至 2021 年 12 月，测试期为 2022 年 1 月至 2024 年 10 月。

实验结果表明：

1. **相关性分析**：暖启动 GP 框架从 10 个不同的有效 Alpha 起点出发，生成的 10 个 Alpha 之间的平均斯皮尔曼相关系数约为 0.6，且没有产生完全相同的因子。相比之下，传统 GP 的多次运行结果中出现了大量完全相同或高度相关的因子，证明了本框架在缓解过早收敛和结果高相关性方面的优势。

2. **IC 分析**：暖启动 GP 框架显著提升了所选 Alpha101 因子的表现。增强后的因子样本外平均 IC 从 1.5% 提升至 4.7%，平均 RankIC 从 1.9% 提升至 7.8%。与传统 GP 发现的因子相比，本框架发现的因子样本外平均 IC 高出 1% 以上（4.7% vs 3.6%），平均 RankIC 也提升了近 1%（7.8% vs 7.1%），且显示出更轻的过拟合问题。

3. **交易表现**：在回测中，基于本框架挖掘的 Alpha 构建的线性模型，在持有 10 只、30 只和 100 只股票的不同策略下，其累计收益率均显著跑赢市场指数（沪深 300、中证 500 等）、原始的 Alpha101 因子以及传统 GP 因子。在持有 30 只股票时，年化收益率达到 56.4%，夏普比率高达 1.059。

结论：本文提出的带有精心选择的初始化和结构性约束的暖启动 GP 框架，通过将搜索引导至更有前景的区域，有效解决了传统 GP 在 Alpha 因子挖掘中面临的搜索空间巨大、有效解稀疏等问题。基于 2020-2024 年中国股市数据的分析证明，该框架在样本外预测和投资组合回报方面均显著优于传统方法和基准。

4 评述

本文《基于暖启动遗传编程的量化投资 Alpha 挖掘与增强》针对传统遗传编程在量化选股因子（Alpha）挖掘中的效率低下、易于早熟收敛和结果可解释性差等问题，提出了一

种新颖的“暖启动遗传编程”框架。该方法的核心洞察在于，一个有效 Alpha 因子的价值不仅体现在其数学表达式上，更根植于其内在的树形结构。基于此，作者提出了两个关键假设：有效结构能够提高挖掘成功率，且有效因子本身即提供了这样的结构。

该框架的创新之处在于：1）通过选取一个已知的有效因子作为搜索起点，提供了一个强有力的“暖启动”；2）通过设计受限的交叉算子，将整个遗传编程的搜索过程严格限定在起始因子的固定树形结构内。这使得搜索从盲目的全局探索转变为在更有希望的局部空间内的精细化“增强”，从而显著提升了搜索效率和结果的可靠性。

在 2020 年至 2024 年中国 A 股市场的数据上进行实证分析，结果有力地验证了该方法的优越性。与传统的遗传编程和著名的 Alpha101 因子相比，通过该框架挖掘并增强的因子不仅具有更高的信息系数（IC）和信息比率（ICIR），表现出更强的样本外预测能力和稳定性，而且在投资组合回测中实现了显著的超额收益和更高的夏普比率。此外，该方法还通过保持结构不变，有效降低了因子间的相关性，缓解了传统方法中常见的同质化问题，并增强了因子的可解释性。

5 外文翻译小结

总而言之，这项研究为解决遗传编程在金融领域应用的关键难题提供了一个优雅且高效的思路。它通过模仿人类专家的构建逻辑，将无方向的随机搜索转化为有引导的结构化探索，实现了从“挖掘”到“增强”的范式转变。该工作不仅在理论上具有启发性，其实证结果也充分展示了其在量化投资实践中的巨大潜力和应用价值。未来的研究可以在此基础上，探索更复杂的因子聚合模型以及进一步优化遗传编程的计算效率。

6 外文翻译参考文献

参考文献

[1] Allen, F. and Karjalainen, R. Using genetic algorithms to find technical trading rules. *Journal of Financial Economics*, 51(2):245–271, February 1999.

[2] Becker, Y. L. and O'Reilly, U. M. Genetic programming for quantitative stock selection. In *Proceedings of the First ACM/SIGEVO Summit on Genetic and Evolutionary Computation*, pp. 9–16, 2009.

[3] Brabazon, A., Kampouridis, M., and O'Neill, M. Applications of genetic programming to finance and economics: Past, present, future. *Genetic Programming and Evolvable Machines*, 21:33–53, 2020.

[4] Chen, J. Finding unique alphas: Genetic algorithms and genetic programming. Technical report, Shenwan Hongyuan, September 2016.

[5] Cui, C., Wang, W., Zhang, M., Chen, G., Luo, Z., and Ooi, B. C. Alphaevolve: A learning framework to discover novel alphas in quantitative investment. In *Proceedings of the 2021 International Conference on Management of Data*, pp. 2208–2216, June 2021.

[6] Fama, E. F. and French, K. R. Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1):3–56, 1993.

[7] Fama, E. F. and French, K. R. A five-factor asset pricing model. *Journal of Financial Economics*, 116(1):1–22, 2015.

[8] Feng, F., He, X., Wang, X., Luo, C., Liu, Y., and Chua, T. S. Temporal relational ranking for stock prediction. *ACM Transactions on Information Systems (TOIS)*, 37(2):1–30, 2019.

[9] Gupta, D. and Ghafir, S. An overview of methods maintaining diversity in genetic algorithms. *International Journal of Emerging Technology and Advanced Engineering*, 2(5):56–60, 2012.

[10] Kakushadze, Z. 101 formulaic alphas. *Wilmott*, 2016(84):72–81, July 2016.

[11] Kim, M., Becker, Y. L., Fei, P., and O'Reilly, U. M. Constrained genetic programming to minimize overfitting in stock selection. In *Genetic Programming Theory and Practice VI, Genetic and Evolutionary Computation*, pp. 179–195, 2008.

[12] Koza, J. R. *Genetic Programming: On the Programming of Computers by Means of Natural Selection*. MIT Press, 1992.

[13] Li, C. and Liu, F. A multi-factor stock selection system based on short-term price and volume characteristics. Technical report, Guotai Junan, June 2017.

[14] Lin, X. and Chen, Y. Stock selection factor mining based on genetic programming. Technical report, Huatai Securities, June 2019a.

[15] Lin, X. and Chen, Y. Re-examining stock selection factor mining based on genetic programming. Technical report, Huatai Securities, August 2019b.

[16] Lin, X. and He, K. Gpu acceleration for genetic programming factor mining. Technical report, Huatai Securities, February 2024.

[17] Long, X., Kampouridis, M., and Jarchi, D. An in-depth investigation of genetic programming and nine other machine learning algorithms in a financial forecasting problem. In *2022 IEEE Congress on Evolutionary Computation (CEC)*, pp. 01–08. IEEE, July 2022.

[18] Narang, R. K. *Inside the Black Box: A Simple Guide to Quantitative and High-Frequency Trading*, volume 846. John Wiley & Sons, 2013.

[19] O'Neill, M., Vanneschi, L., Gustafson, S., and Banzhaf, W. Open issues in genetic programming. *Genetic Programming and Evolvable Machines*, 11:339–363, 2010.

[20] Sharpe, W. F. Capital asset prices: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, 19(3):425–442, 1964.

[21] Soule, T. and Heckendorn, R. B. An analysis of the causes of code growth in genetic programming. *Genetic Programming and Evolvable Machines*, 3:283–309, 2002.

[22] Xia, Y., Tian, S. P., Wei, H. Y., and Wang, Z. W. Research on symbolic regression based on genetic programming. *Journal of China Jiliang University*, 17(2):128–131, 2006.

[23] Zhang, H. Genetic programming deconstruction and investment insights. Technical report, Guotai Junan, August 2023.

[24] Zhang, T., Li, Y., Jin, Y., and Li, J. Autoalpha: An efficient hierarchical evolutionary algorithm for mining alpha factors in quantitative investment. *arXiv preprint arXiv:2002.08245*, 2020.

[25] Zhaofan, S., Jianwu, L., and Chengshan, Z. Genetic algorithm based quantitative factors construction. In *2022 IEEE 20th International Conference on Industrial Informatics (INDIN)*, pp. 650–655. IEEE, 2022.

四、外文原文

Alpha Mining and Enhancing via Warm Start Genetic Programming for Quantitative Investment

Weizhe Ren [1] **Yichen Qin** [2] **Yang Li** [1]

arXiv:2412.00896v1 [q-fin.ST] 1 Dec 2024

Abstract

Traditional genetic programming (GP) often struggles in stock alpha factor discovery due to its vast search space, overwhelming computational burden, and sporadic effective alphas. We find that GP performs better when focusing on promising regions rather than random searching. This paper proposes a new GP framework with carefully chosen initialization and structural constraints to enhance search performance and improve the interpretability of the alpha factors. This approach is motivated by and mimics the alpha searching practice and aims to boost the efficiency of such a process. Analysis of 2020-2024 Chinese stock market data shows that our method yields superior out-of-sample prediction results and higher portfolio returns than the benchmark.

1. Introduction

Predicting future stock returns is one of the most challenging tasks in quantitative trading. Stock prices are influenced by numerous factors, such as company performance, investor sentiment, government policies, and other relevant variables. To explain stock market fluctuations, economists have developed a variety of theoretical models, including the Capital Asset Pricing Model (CAPM) (Sharpe, 1964), the Fama-French three-factor model (Fama & French, 1993), the Fama-French five-factor model (Fama & French, 2015), and others. In quantitative trading practice, designing new factors that can explain and predict asset returns is crucial to the profitability of a strategy. Such factors are typically referred to as alphas, alpha factors or stock selection factors. Narang (2013) defines stock selection as "the process of using data-driven methods to build models, select stocks that are expected to perform well in the future, and generate returns." Based on this understanding, the value of an alpha factor of a given stock on a specific trading day can be seen as a prediction of its future returns: the higher the value, the more likely the stock is to achieve relatively higher returns in the future.

Traditionally, new alphas have typically been generated through theoretical hypotheses proposed by economists or financial engineers, which are then converted into mathematical formulas and subsequently validated using historical data. These manually constructed alphas generally exhibit strong interpretability and stability. However, they are often unable to capture complex nonlinear relationships within the data. Moreover, the manual construction process is not only time-consuming but also requires extensive investment experience (Feng et al., 2019), making it difficult to generalize to the broader investing community (Becker & O'Reilly, 2009).

With the advent of the big data era and advancements in computational power, both academia and the financial industry have gradually shifted towards data-driven, automated alpha discovery methods, particularly those based on trading data, such as trading volume, transaction prices, turnover rate, etc, to extract more complex market information. Such data is often more real-time and can reflect the dynamic characteristics of stock price movements, from which more accurate and forward-looking alphas can often be uncovered (Cui et al., 2021).

Among the automated methods for alpha discovery, genetic programming-based method is one of the most popular approaches. Genetic programming (GP) can yield formulaic factors based on simple mathematical structures, which are more interpretable, easier to understand and apply, and can be modified promptly. Therefore, how to use GP to derive stock selection factors with good performance has become a key focus for many economists and financial researchers.

Genetic Programming is a branch of Genetic Algorithms (GA). In GP, solutions are represented in a tree-like structure, where the root node represents operators and the leaf nodes represent input data or variables, as shown in the Figure 1. This structure enables GP to generate complex programs or formulas (Koza, 1992). Like GA, GP optimizes the target

[1]Center for Applied Statistics and School of Statistics, Renmin University of China, Beijing, China [2]Department of Operations, Business Analytics, and Information Systems, University of Cincinnati, Cincinnati, OH. Correspondence to: Yang Li <yang.li@ruc.edu.cn>.

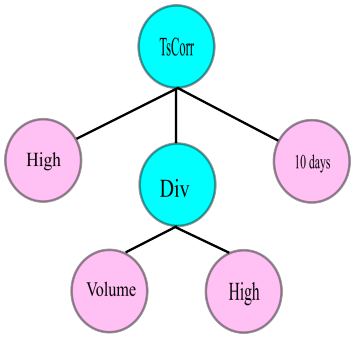


Figure 1. An example of a GP tree. The green parts are root nodes and the pink parts are leaf nodes.

solutions using the concept of biological evolution. In the context of alpha discovery, traditional GP begins by randomly generating an initial population of factors. Starting from this initial population, GP uses specific rules to select individuals. The selected individuals undergo crossover or mutation to produce offspring (similar to chromosome crossover and mutation in genetic evolution), resulting in a new population with new genetic traits. The process continues by updating the individuals' fitness values to identify the best solution (Xia et al., 2006).

In the field of mining stock selection factors, the most commonly used fitness measure is the Information Coefficient (IC), which can reflect the stock selection ability of a single alpha. The calculation formula for IC is as follows, where the IC of an alpha is obtained by averaging the daily cross-sectional IC values over a period of time, and the cross-sectional IC represents the correlation between the alpha values and future returns on a given day. [1]

$$IC = \frac{1}{T}\sum_{t=1}^{T} \text{PearsonCorr}(\mathbf{a}_t, \mathbf{r}_t)$$

where $\mathbf{a}_t$ is the value vector of the alpha at date t, $\mathbf{r}_t$ is the value vector of the forward returns at date t. In this paper, we use the five-day VWAP [2] cumulative return as our future return, where $\mathbf{r}_t = \frac{\text{VWAP}_{t+6}}{\text{VWAP}_{t+1}} - 1$.

As early as 1995, Allen & Karjalainen (1999) introduced GP into the field of stock investment. In 2016, the quantitative investment management firm WorldQuant released a report titled "WorldQuant: Formulaic 101 Alphas," in which they disclosed 101 formulaic alphas derived using GP (Kakushadze, 2016). In 2017, Guotai Junan Securities used GP to construct 191 short-term stock selection factors and applied them to build a multi-factor stock selection strategy (Li & Liu, 2017). To this day, a large amount of quantitative trading still relies on GP to mine formulaic alphas for predicting stock trends (Chen, 2016; Lin & Chen, 2019a;b; Zhang, 2023; Lin & He, 2024).

2. Problem Statement

As research and applications increasingly focus on using GP to mine alphas for stock selection, several challenges associated with this method have emerged. O'Neill et al. (2010) raised some major open issues and development directions that need to be addressed in general GP. Brabazon et al. (2020) discussed the significant potential of GP in the financial domain but highlighted that its applications are predominantly experimental implementations of computer science on financial data, with limited exploration in financial literature. They further analyzed issues related to GP's scalability, benchmarking, and data snooping, offering explanations and future prospects. Kim et al. (2008) proposed a constrained tree structure to reduce the risk of overfitting in GP. Long et al. (2022) identified two advanced methods that could improve the application of GP in alpha mining: multi-objective GP to simulate trade-offs in real-world trading and tree structure constraints to mitigate overfitting risks. Gupta & Ghafir (2012) highlighted the premature convergence problem in genetic algorithms, where a single effective gene dominates the population, reducing diversity and trapping the population in suboptimal states. Similarly, Zhang et al. (2020) identified three challenges in using GP for alpha mining: rapidly identifying promising search spaces, guiding searches away from already explored areas, and preventing premature convergence.

In our implementation of traditional GP for alpha mining, the most significant challenges are the infinite search space and the sparsity of effective alphas. The infinite search space arises from the unrestricted growth in the depth and length of tree-structured alphas. On the other hand, even manually designing effective stock selection factors is a non-trivial task, indicating that effective alphas are naturally sparse within such an enormous search space. To better understand this sparsity, we design an experiment to validate it. Using traditional GP, we randomly generate 10,000 alphas on a little test data set and find that fewer than 3% are effective (with an $IC > 0.03$ [3]), while the vast majority of alphas had IC values close to 0, as shown in the Figure 2. This result more intuitively illustrates the sparsity of effective alphas.

The infinite search space and sparse effective solutions lead to the following specific issues:

[1] We assume all IC metrics are ≥ 0, as negative IC values can be flipped by multiplying the alpha by -1.

[2] VWAP is short for the Volume Weighted Average Price.

[3] In this experiment, we assume an alpha with an IC greater than 0.03 is considered effective.

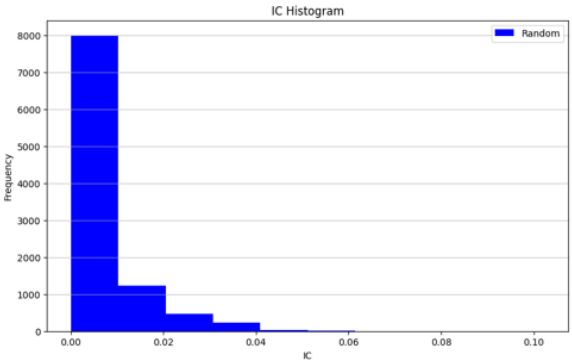


Figure 2. The results indicate that effective alphas are sparse within the search space of traditional GP.

- **Inefficient Search Process:** The infinite search space, sparse effective alphas, and financial data complexity make traditional GP inefficient in finding stock selection factors. The "code bloat" problem also further hampers search efficiency (Soule & Heckendorn, 2002).

- **Premature Convergence:** Due to the scarcity of effective solutions, once a local optimum is found, a dominant gene quickly takes over the population, causing stagnation and high correlation in the results (Gupta & Ghafir, 2012).

- **Poor interpretability:** Random search in large spaces can find alphas that perform well numerically but are too complex or difficult to interpret, making them hard to apply in quantitative trading.

Some related works have attempted to address these issues. For example, Gupta & Ghafir (2012) proposed several methods to mitigate premature convergence, such as *Warm Start* and *Replacement Method*. Zhang et al. (2020) introduced a hierarchical structure to improve the traditional GP framework. Zhaofan et al. (2022) suggested penalizing the correlation between newly generated alphas and existing ones in the pool to reduce the risk of high correlation. Additionally, Zhang et al. (2020) also proposed a *PCA-QD* method, which used principal component correlation as a substitute for traditional correlation measures to reduce computational overhead.

In this paper, we propose a new GP framework with carefully chosen initialization and structural constraints, which helps mitigate the aforementioned challenges and achieves promising results in empirical analysis. The main contributions of this paper are as follows:

- **Providing a Strong Starting Point:** We improve GP's initialization by offering a well-chosen starting point, reducing inefficiencies and enhancing search performance. We also propose a simple principle for selecting the initial point.

- **Constraining the Tree Structure:** We restrict GP's search to a predefined tree structure, supported by a new designed crossover operator that swaps subtrees at equivalent positions within the same structure. This approach also ensures the interpretability of the alphas.

- **Addressing Premature Convergence and High Correlation:** We mitigate premature convergence by avoiding duplicate individuals and reduce result correlation through parallel alpha mining across multiple structures.

- **Empirical Validation in the Chinese Stock Market:** Using Chinese stock market data, we demonstrate the proposed framework's superiority over traditional GP and benchmarks in factor mining (IC analysis) and factor returns (Portfolio).

As mentioned above, our framework provides a strong starting point and restricts the alpha search to a given structure. This means initializing the genetic search from a well-designed starting point, while limiting the search to a promising space around the given starting point. Therefore, we believe that, in a sense, our framework represents another novel approach to providing a warm start for GP. Therefore, in the following sections, we will sometimes refer to our framework as the **Warm Start GP** framework.

3. Framework Details

3.1. Motivation

After a period of exploring traditional GP, we quickly shift our research focus to identifying effective search spaces. With a set of alpha factors already proven to be relatively effective, we aim to construct a potential space centered around these alphas and analyze the distribution of effective alphas within this smaller search space. If the distribution of effective alphas in this space is proven denser than in the full search space, we would have identified the desired *effective search space*. Building on this, we could establish not only a framework for mining effective alphas but also a *alpha enhancer*, effectively strengthening the given initial alphas. However, a crucial question remains: how should we define this potential space centered around a specific alpha?

To address this question and make our results more relevant to the Chinese stock market, we review nearly all recent factor construction reports from leading Chinese securities firms. Our approach is inspired by the practices these firms

follow when manually constructing alphas. Observe the following four alphas:

- $Alpha_1$: Rank the ***daily intraday returns*** of the past 20 days by ***the same day's turnover rate***, and average the top 5.
- $Alpha_2$: Rank the ***daily intraday turnover rates*** of the past 20 days by ***the next day's overnight turnover rate***, and average the top 5.
- $Alpha_3$: Rank the ***overnight returns*** of the past 20 days by ***the previous day's turnover rate***, and average the top 5.
- $Alpha_4$: Rank the ***daily intraday turnover rates*** of the past 20 days by ***the same day's intraday returns***, and average the top 5."

The four alphas mentioned above are all manually constructed by securities firms and have proven effective for actual trading. From these alphas, a clear construction pattern can be extracted:

- Rank the $\boldsymbol{Data}_1$ of the past 20 days by $\boldsymbol{Data}_2$, and average the top 5.

This pattern can be further generalized as:

- Rank the $\boldsymbol{Data}_1$ of the past $\boldsymbol{D}$ days by $\boldsymbol{Data}_2$, and select a ***subset*** of values to compute a ***statistical measure***.

The *"subset"* can be the top 5, top 10, or bottom 10, and the *"statistical measure"* can be the mean, standard deviation, median, or even mode. Mapping this fixed pattern to formula-based or tree-structured alphas corresponds to a predefined alpha structure or a fixed tree structure. Examples like these are abundant. Inspired by this observation, we propose the following Hypothesis 1:

Hypothesis 1. *An alpha's effectiveness comes not only from its variables and functions but also from its underlying structure.*

Put more intuitively, an effective alpha structure increases the likelihood of identifying impactful alphas, which means maintaining the structure of an effective alpha while modifying its data or functions increases the chances of discovering a new effective alpha compared to random construction. The Figure 3 illustrates the concept of identical structures in tree-based formulas. All four alphas share a uniform structure consisting of one root node and two leaf nodes with a depth of 1. Under the Hypothesis 1, if the structure of Alpha1 is effective, Alphas2, 3, and 4 are more likely to be effective as well, as they share the same structure.

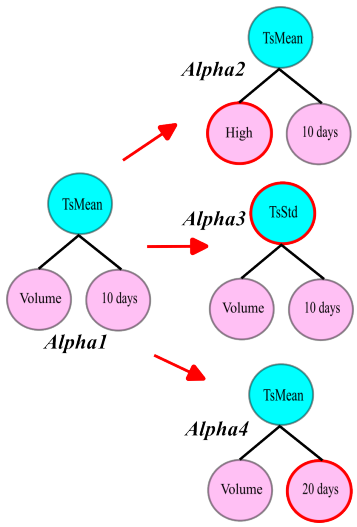


Figure 3. Alphas2, 3, and 4 are alphas that share the same structure as the effective Alpha1.

3.2. Identify an Effective Alpha Structure

Hypothesis1 suggests that if we have an effective alpha structure, we can more efficiently identify effective stock selection factors within this structure. This is an encouraging discovery, but a new question arises: how do we define and identify an effective alpha structure? Undoubtedly, we could rely on economists or financial engineers to design such a structure for us, as some securities firms are doing. However, not every investor has such extensive investment experience or economic knowledge. So it is essential to develop a method for efficiently and intuitively identifying effective alpha structures, ensuring the framework's accessibility and usability for a broader range of investors.

To address this challenge, we propose Hypothesis 2:

Hypothesis 2. *An effective alpha is often characterized by an effective structure.*

This hypothesis offers investors a simple and practical principle for selecting effective structures:

If an alpha is validated as effective, its underlying structure is also effective and can be used to construct an effective search space.

In other words, investors can simply identify an effective alpha and adopt its structure. Moreover, alphas that were highly effective in the past but are temporarily ineffective can also be considered. While their theoretical basis may still be under investigation, our experiments show that these structures are often valid, leading us to speculate that short-term inefficacy may be due to certain data or functions not

accurately reflecting the current market, rather than a failure of the factor structure itself. Finally, while any eligible alpha can be selected, it's preferable to choose those with simple structures, clear functions, and strong interpretability, given computational constraints.

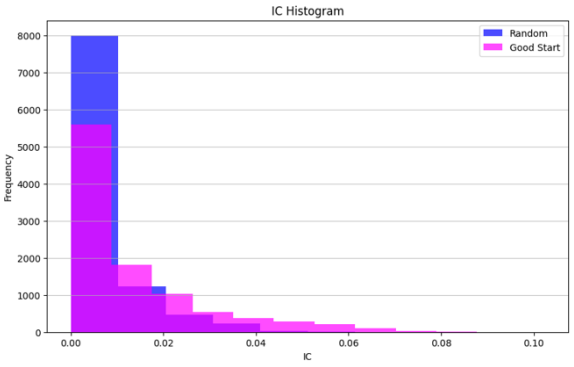


Figure 4. The blue segment represents fully random results, previously shown in Figure2, while the purple segment reflects the results obtained under the given structural constraints.

To validate Hypothesis 1 and Hypothesis 2, we conduct an additional experiment. Specifically, we select an alpha from the Alpha101 [4] set and randomly generate another 10,000 alphas on dataset consistent with the experiment in Figure 2, within the structural constraints of this alpha. The results are then compared with those in Figure 2, as illustrated in Figure4. The findings reveal a substantial increase in the density of effective alphas within the constrained search space. The proportion of alphas with $IC > 0.03$ exceeded 13%, more than tripling the density observed in the unconstrained space. This outcome confirms Hypothesis 1. Furthermore, since the structure used in this experiment originated from a known effective alpha, Hypothesis 2 is also validated.

3.3. Warm Start GP Framework

Based on the two hypotheses outlined above, this paper proposes a framework for mining stock selection factors using genetic programming with given initialization and structural constraints. The proposed framework provides GP with a strong starting point, which is a single individual rather than the traditional initial population in traditional GP. This initial individual not only provides a good starting point for the search, accelerating convergence, but also offers an effective alpha structure. The selection principle for this initial individual is guided by Hypothesis 2. Starting from this initial individual, our framework restricts the search to the structure possessed by this individual, continuing until the termination condition is met or the maximum number of iterations is reached, after which the best individual found within the structure is output.

Moreover, our framework is not only a robust alpha mining framework but also an excellent alpha enhancing framework. In fact, within our framework, these two concepts are equivalent. We provide GP with a good starting point as a warm start, which not only locates the initial position but also locks in a small search space. From one perspective, this approach allows for quick identification of an effective search space, thus speeding up the alpha search process. From another perspective, if we focus on the given starting point - the chosen effective alpha - itself, the work we are actually doing is enhancing the given alpha. Returning to Figure 3, you will notice that Alphas2, 3, and 4 are all attempts to enhance Alpha1. In reality, our framework operates in precisely this manner: it aims to improve the performance of a given alpha by making modifications that do not disrupt the structure of the alpha.

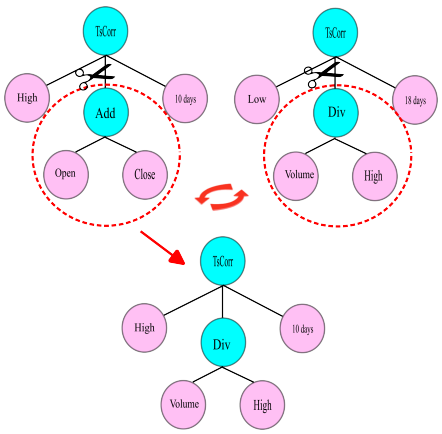


Figure 5. The restricted crossover: only allows alphas with the same structure to exchange subtrees at the same positions, ensuring that the alpha structure remains unchanged.

The Algorithm 1 provides a detailed explanation of how to search for superior alphas within the structure of a given alpha factor. The key distinction of the proposed framework compared to traditional GP lies in starting from a known effective alpha and restricting the search to its predefined structure. To implement this critical distinction, we design a **Restricted Crossover Operator**, allowing only restricted crossover and point mutation during the crossover and mutation phases, ensuring that the alpha structure remains unchanged throughout the search process. The restricted crossover operator supports the exchange of iden-

[4]The majority of the alphas in Alpha101 have been validated as effective by both the U.S. and Chinese markets. The alpha selected for our experiment is Alpha33.

Algorithm 1 Warm Start GP Framework

input Fitness function $f(\cdot)$, Population size n_{pop}, Mutation rates $P = (p_{\text{crossover}}, p_{\text{point}})$, other initial params $Params_{init}$, Stock data $\mathbf{X}$, Forward return $\mathbf{Y}$, initial alpha $alpha_{init}$
output An enhanced alpha

1: $t \leftarrow 0$
2: $Pop(t) \leftarrow alpha_{init}$
3: EvaluatePopulation($Pop(t)$)
4: **while** not terminate **do**
5: $Pop(t+1)$ Insert argmax $f(Pop(t))$
6: **while** len($Pop(t+1)$) $< n_{\text{pop}}$ **do**
7: **if** $t+1 == 1$ **then**
8: $Mutation \leftarrow$ PointMutation
9: **else**
10: $Mutation \leftarrow$ Choose method randomly(P)
11: **end if**
12: **if** $Mutation$ == Crossover **then**
13: $P_1 \leftarrow$ Tournament($Pop(t)$)
14: $P_2 \leftarrow$ Tournament($Pop(t)$)
15: $Offspring \leftarrow$ Crossover(P_1, P_2)
16: **else**
17: **if** $Mutation$ == PointMutation **then**
18: $P_1 \leftarrow$ Tournament($Pop(t)$)
19: $Offspring \leftarrow$ PointMutation(P_1)
20: **else**
21: $P_1 \leftarrow$ Tournament($Pop(t)$)
22: $Offspring \leftarrow P_1$
23: **end if**
24: **end if**
25: **if** $Offspring$ NOT IN $Pop(t+1)$ **then**
26: $Pop(t+1)$ Insert $Offspring$
27: **end if**
28: **end while**
29: EvaluatePopulation($Pop(t+1)$)
30: $t \leftarrow t+1$
31: **end while**

tical subtrees at the same positions between alphas of the same structure, thereby preserving the alpha structure. This step is detailed in line 15 of the Algorithm 1 and is illustrated with a simple example of restricted crossover in Figure 5. In this paper, the effective alpha structures we selected all come from Alpha101.

Since the first generation at $t = 0$ contains only a single given individual, crossover and mutation cannot be applied to a single individual. Thus, during the construction of the second generation ($t + 1 = 1$ in the algorithm), only point mutation is allowed to ensure the generation of a sufficient number of alphas with the same structure but different details. For generations with $t > 1$, selected parents undergo restricted crossover or point mutation with a given probability, and through the process of selection and elimination, the final population is obtained.

A few points require clarification: We use the tournament selection method to choose parents. In line 5, we ensure the best individual from the previous generation is carried over to prevent performance decline. In line 25, we avoid duplicate individuals in the next generation to prevent rapid gene domination. Finally, the algorithm starts from a single point, but practical applications often use parallel searches from multiple starting points.

3.4. Why Warm Start GP framework

In the former Sections, we briefly introduced the benefits of using valid initial alphas and structures. Here, we elaborate on the advantages of the proposed framework:

- **Warm Start with Efficient, Finite Search Space:** As shown in Figure 4, selecting an effective alpha structure focuses the search on a sub-space that is not only more efficient but also finite. An effective and finite search space, combined with a well-defined starting point, enables our framework to demonstrate strong performance in alpha mining tasks. Additionally, restricting the tree structure completely avoids the "code bloat" problem, improving computational efficiency.

- **A Strong Alpha Enhancer:** A finite search space ensures that, in theory, the optimal solution under the sapce can be found. This means another strength of our framework, as even with other more efficient alpha-mining methods, the proposed framework can serve as an **"Alpha Enhancer"** to improve the alphas obtained.

- **Reducing Overfitting Risk and improving interpretability:** Traditional GP incline to increase solution depth and length to improve performance, but this can lead to poor out-of-sample results. Evidence from Gupta & Ghafir (2012) suggests that restricting the search to a given structure can mitigate this risk. In addition, constraining the structure of the alphas means we can provide well-defined, interpretable structures and prevent the alphas from becoming unrecognizable. This significantly enhances the interpretability of the resulting alphas.

- **Reducing Premature Convergence and High Correlation Issues:** The proposed framework prevents the entry of duplicate individuals into the population, reducing the likelihood of domination by a small set of genes. Furthermore, since our framework works within a single structure and we expect only one optimal individual, the likelihood of high correlation among individuals across different structures becomes lower.

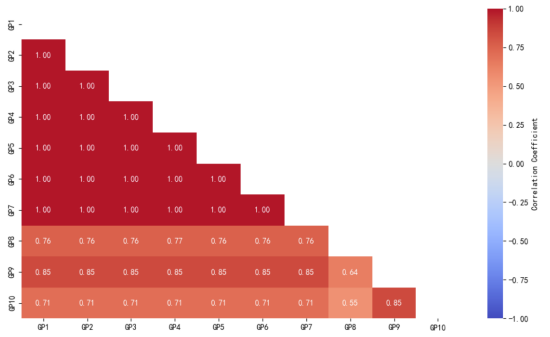
The advantages of the proposed framework outlined above will be further validated and demonstrated in detail in the next section through empirical analysis.

4. Numerical Results

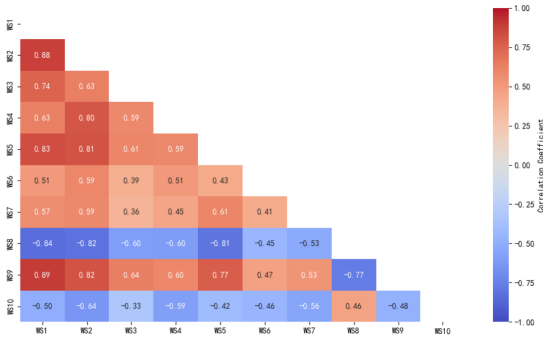
4.1. Experiment Settings

To validate the several mentioned advantages of the proposed framework in alpha mining, we conduct experiments on **Correlation Analysis**, **IC Analysis**, and **Trading Performance**. We set a 5-day holding period to evaluate the alpha's ability to predict stock returns. Starting with 10 effective alphas from Alpha101, we use our framework to generate 10 high-quality alphas and compare the results with both the chosen Alpha101 alphas and those generated by traditional GP.

Datasets: We use the full A-shares data of the Chinese stock market for alpha discovery, with the alpha mining period spanning from 2020.01 to 2021.12. The testing period is set from 2022.01 to 2024.10.



a. GP: average absolute value 0.87



b. Warm Start GP: average absolute value 0.60

Figure 6. Correlation coefficients of GP alphas (a.) and WS alphas (b.).

4.2. Correlation Analysis

We aim for each GP program to generate distinct, high-quality alphas, as highly correlated or identical factors can harm downstream tasks (e.g., multicollinearity). Traditional GP often gets stuck in local optima, leading to highly correlated results both within a single run and across multiple runs. The Figure 6 below shows Spearman correlations among the 10 best alphas from 10 traditional GP runs, where seven runs even produce identical factors—an outcome we seek to avoid.

The alphas derived from different starting points by the Warm Start GP framework [5] reduce the average correlation to around 0.6, without producing identical factors, demonstrating its advantage over traditional GP in mitigating high correlation.

4.3. IC Analysis

The IC analysis method is commonly used to evaluate alpha effectiveness. The evaluation metrics we use are IC, ICIR, RankIC, and RankICIR, where RankIC replaces the Pearson correlation with the Spearman correlation in calculating IC, and ICIR is the ratio of the mean IC to its standard deviation, reflecting alpha significance and stability:

$$ICIR = \frac{IC}{\text{std}(\text{PearsonCorr}(\mathbf{a}_t, \mathbf{r}_t)}$$

$$RankIC = \frac{1}{T}\sum_{t=1}^{T} \text{SpearmanCorr}(\mathbf{a}_t, \mathbf{r}_t)$$

$$RankICIR = \frac{RankIC}{\text{std}(\text{SpearmanCorr}(\mathbf{a}_t, \mathbf{r}_t)}$$

Larger values of these metrics are better.

In the IC analysis, we first demonstrate how the proposed framework enhances the initial alphas from Alpha101 set. We compare the IC metrics before and after enhancement and the results are presented in Table 1. We also perform an IC analysis on the top 10 alphas generated by traditional GP in Table 2 to assess whether our framework provides an improvement over traditional GP in the alpha mining task for quantitative investment. To avoid duplication, we select the second-best alpha when there are repeats among the top 10 GP alphas, ensuring each GP program contributed a unique alpha.

According to the results in Table 1, the proposed framework significantly improve the performance of the selected Alpha101 alphas, with the average in-sample IC increasing from 1% to over 3%, and the average RankIC rising to **6.8**%. The result also shows that this improvement is maintained

[5] These are referred to as **WS** alphas in the Figure 6

Table 1. IC analysis results of the selected starting points from Alpha101 (A101), with "#" indicating its code in the Alpha101 set, and the corresponding alphas enhanced by our proposed framework (WS), sorted by the out-of-sample IC of the WS alphas. The results outside (inside) the brackets indicate out-of-sample (in-sample) results, with the sample division being consistent with the mining and testing period split in Experiment Settings.

#	IC		$ICIR$		$RankIC$		$RankICIR$	
	A101	WS	A101	WS	A101	WS	A101	WS
a_{025}	0.011(0.011)	**0.060**(0.035)	0.11(0.14)	**0.46**(0.24)	0.011(0.013)	**0.091**(0.067)	0.09(0.13)	**0.59**(0.38)
a_{067}	0.000(0.000)	**0.056**(0.033)	0.00(0.00)	**0.47**(0.24)	0.000(0.000)	**0.081**(0.066)	0.00(0.00)	**0.57**(0.42)
a_{047}	0.015(0.013)	**0.051**(0.035)	0.14(0.16)	**0.54**(0.33)	0.005(0.011)	**0.085**(0.073)	0.03(0.11)	**0.76**(0.61)
a_{005}	0.013(0.003)	**0.051**(0.034)	0.17(0.04)	**0.43**(0.26)	0.006(0.002)	**0.082**(0.069)	0.06(0.02)	**0.56**(0.45)
a_{090}	0.004(0.013)	**0.050**(0.032)	0.04(0.16)	**0.45**(0.26)	0.007(0.011)	**0.076**(0.064)	0.06(0.11)	**0.57**(0.47)
a_{008}	0.018(0.013)	**0.048**(0.033)	0.18(0.18)	**0.42**(0.25)	0.022(0.019)	**0.089**(0.077)	0.18(0.23)	**0.67**(0.49)
a_{040}	0.036(0.028)	**0.042**(0.034)	0.41(0.37)	**0.48**(0.43)	0.069(0.057)	**0.076**(0.068)	0.67(0.63)	**0.78**(0.73)
a_{011}	0.001(0.004)	**0.042**(0.035)	0.02(0.06)	**0.42**(0.33)	0.006(0.000)	**0.058**(0.056)	0.06(0.00)	**0.46**(0.45)
a_{018}	0.029(0.022)	**0.037**(0.041)	0.30(0.25)	**0.36**(0.36)	0.041(0.037)	**0.075**(0.080)	0.36(0.36)	**0.62**(0.57)
a_{101}	0.018(0.011)	**0.033**(0.033)	0.16(0.14)	**0.24**(0.27)	0.019(0.016)	**0.066**(0.066)	0.15(0.18)	**0.42**(0.49)
avg	0.015(0.012)	**0.047**(0.034)	0.15(0.15)	**0.43**(0.30)	0.019(0.017)	**0.078**(0.068)	0.17(0.18)	**0.60**(0.51)

Table 2. Out-of-(in-) Sample IC performances of traditional GP alphas, sorted by the out-of-sample IC of the GP alphas

#	IC	$ICIR$	$RankIC$	$RankICIR$
1	0.056 (0.034)	0.48 (0.26)	0.085 (0.066)	0.60 (0.44)
2	0.055 (0.032)	0.47 (0.25)	0.084 (0.067)	0.59 (0.44)
3	0.039 (0.030)	0.33 (0.26)	0.070 (0.072)	0.53 (0.61)
4	0.036 (0.037)	0.28 (0.30)	0.078 (0.079)	0.53 (0.55)
5	0.036 (0.040)	0.26 (0.31)	0.073 (0.077)	0.45 (0.52)
6	0.034 (0.038)	0.30 (0.35)	0.072 (0.077)	0.53 (0.60)
7	0.030 (0.038)	0.22 (0.30)	0.063 (0.076)	0.40 (0.52)
8	0.028 (0.037)	0.23 (0.33)	0.067 (0.077)	0.46 (0.58)
9	0.028 (0.036)	0.21 (0.27)	0.064 (0.074)	0.39 (0.47)
10	0.022 (0.038)	0.18 (0.35)	0.055 (0.070)	0.37 (0.53)
avg	0.036 (0.036)	0.30 (0.30)	0.071 (0.074)	0.48 (0.52)

out-of-sample. While the original alphas show little difference in performance between in- and out-of-sample, the enhanced alphas perform even better out-of-sample, with an average IC of **4.7**% and RankIC of **7.8**%. These results confirm that our framework enhances alphas from a solid starting point, with clear improvements both in- and out-of-sample.

Compared to traditional GP, the proposed framework also demonstrates a significant advantage in out-of-sample alpha performance. The alphas identified by our framework have an average out-of-sample IC that is more than **1**% higher than those from traditional GP, and the average RankIC has increased **1**%, let alone a more pronounced advantage in ICIR and RankICIR. Considering that our framework does not have an advantage over traditional GP in-sample, the comparison results in Tables 1 and 2 demonstrate that the alphas discovered by our framework not only outperform those from traditional methods, but also alleviate the overfitting problem commonly seen in traditional GP.

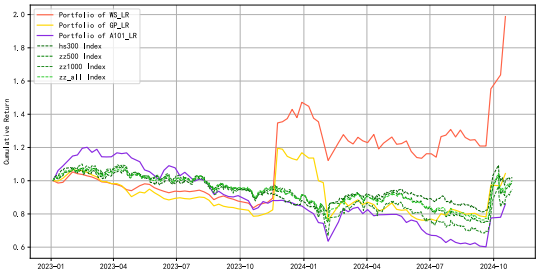
4.4. Trading Performance

IC analysis is one aspect of measuring the effectiveness of an alpha. For actual trading, the alpha's ability to generate excess returns is more critical. We use the backtesting results of the alphas to assess their ability to capture excess returns.

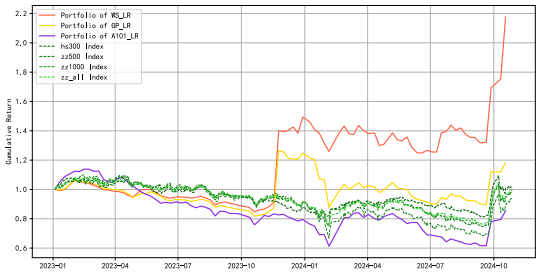
- **Backtesting Setup:** To avoid using future information in any trade, we split the test period into two segments: 2022.1 to 2022.12 for training the alpha model, and 2023.1 to 2024.10 for forecasting future returns by the trained alpha model. To simulate real trading conditions, we apply the following restrictions: stocks cannot be bought if hitting the daily limit-up, and cannot be sold if hitting the limit-down or being suspended. Transaction costs are 0.6‰.
- **Investment Strategy:** The holding period is set to 5 trading days. At each rebalancing, we invest in the top-ranked stocks with equally distributed capital. If a stock cannot be bought, its allocation is redistributed to the remaining top-ranked stocks. We set different holding sizes: 10, 30, and 100 stocks. The buy and sell prices are set to be the VWAP of the day. Furthermore, we set a rule that if a stock is flagged with an ST or *ST warning, we will no longer hold that stock, which is a common risk-aversion measure in real-world trading.
- **Alpha Model:** For simplicity, we opt for a linear regression model to fit the alpha factors. The predicted value on day T is the forecasted cumulative return of

the VWAP from day *T+1* to day *T+6*. Thus, when executing trades on day *T*, stock rankings are based on the predicted returns from day *T-1*.

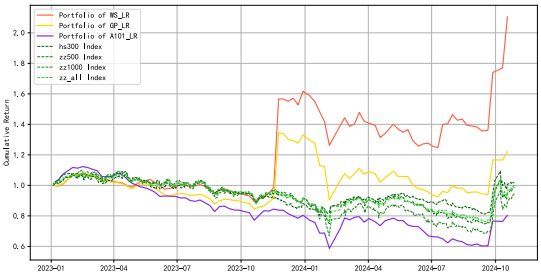
- **Benchmark:** We construct alpha models for the alphas generated by our framework, the selected Alpha101 alphas, and traditional GP alphas using data from 2022. Portfolios are then built based on their respective predictions after 2022. Additionally, we select the CSI 300 (hs300) Index, CSI 500 (zz500) Index, CSI 1000 (zz1000) Index, and the CSI All (zz_all) Index as benchmarks representing the market level.



a. Portfolio performance for holding 10 stocks.



b. Portfolio performance for holding 30 stocks.



c. Portfolio performance for holding 100 stocks.

Figure 7. Portfolio performance under different methods and different holding sizes

According to the results in Figure 7, regardless of the number of stocks held, the model constructed based on the alphas extracted from the proposed framework consistently outperforms the market, the Alpha101 alphas before enhancement, and the traditional GP alphas, achieving the highest portfolio returns. We also calculated the annualized return (AR) and Sharpe ratio (SR) of the portfolios constructed by the three alpha models. The calculation formula of SR is:

Table 3. AR and SR results of backtests and comparisons with baselines

#	$Size = 10$		$Size = 30$		$Size = 100$	
	AR	SR	AR	SR	AR	SR
$A101_LR$	-0.083	-0.231	-0.087	-0.253	-0.118	-0.340
GP_LR	0.024	0.052	0.102	0.221	0.122	0.257
WS_LR	**0.484**	**0.937**	**0.564**	**1.059**	**0.534**	**0.959**

$$\text{SR} = \frac{Ret_P - Ret_f}{\sigma_p}$$

where Ret_P is the annualized return of the portfolio, Ret_f is the risk-free rate, which is set to 0 in this paper, and σ_p is the annualized volatility of the portfolio.

The numerical results of AR and SR in Table 3 indicate that the alphas extracted by our framework achieve substantial excess returns far surpassing other benchmarks. The annualized return exceeds **50**% under both 30 and 100 holding sizes, with the Sharpe ratio exceeding **1.0** under the 30 holding size. This suggests that the alphas identified by the proposed framework are not only superficially strong in terms of IC performance, but they also possess significant investment potential, capable of guiding investors in making profitable investment decisions.

5. Conclusion

We identify several key challenges in traditional GP for alpha factor discovery: the vast search space and the sparsity of effective solutions. We find that GP performs better when focusing on promising regions rather than random searching, so we propose a new GP framework with carefully chosen initialization and structural constraints, thereby forcing GP to focus the search on more promising areas, which is motivated by the alpha searching practice and aims to boost the efficiency of such a process. Our analysis of 2020-2024 Chinese stock market data shows that the proposed framework yields superior out-of-sample prediction results and higher portfolio returns than the benchmark.

There are several directions for further research. For example, we employ a simple linear regression model to aggregate the alphas in our work. However, more complex machine learning or deep learning models could be used to enhance the factor aggregation process. Designing specialized models for alpha synthesis is a significant area of future work. Additionally, the computational cost of GP

presents a serious challenge during our experiment. To date, there has been limited rigorous research on the time consumption of GP in the alpha selection process. We believe this is a promising direction for further investigation, such as analyzing which steps consume the most and identifying areas where efficiency can be improved. Addressing these challenges would be instrumental in promoting the broader application of GP-based methods in alpha selection.

References

Allen, F. and Karjalainen, R. Using genetic algorithms to find technical trading rules. *Journal of Financial Economics*, 51(2):245–271, February 1999.

Becker, Y. L. and O'Reilly, U. M. Genetic programming for quantitative stock selection. In *Proceedings of the First ACM/SIGEVO Summit on Genetic and Evolutionary Computation*, pp. 9–16, 2009.

Brabazon, A., Kampouridis, M., and O'Neill, M. Applications of genetic programming to finance and economics: Past, present, future. *Genetic Programming and Evolvable Machines*, 21:33–53, 2020.

Chen, J. Finding unique alphas: Genetic algorithms and genetic programming. Technical report, Shenwan Hongyuan, September 2016.

Cui, C., Wang, W., Zhang, M., Chen, G., Luo, Z., and Ooi, B. C. Alphaevolve: A learning framework to discover novel alphas in quantitative investment. In *Proceedings of the 2021 International Conference on Management of Data*, pp. 2208–2216, June 2021.

Fama, E. F. and French, K. R. Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1):3–56, 1993.

Fama, E. F. and French, K. R. A five-factor asset pricing model. *Journal of Financial Economics*, 116(1):1–22, 2015.

Feng, F., He, X., Wang, X., Luo, C., Liu, Y., and Chua, T. S. Temporal relational ranking for stock prediction. *ACM Transactions on Information Systems (TOIS)*, 37(2):1–30, 2019.

Gupta, D. and Ghafir, S. An overview of methods maintaining diversity in genetic algorithms. *International Journal of Emerging Technology and Advanced Engineering*, 2 (5):56–60, 2012.

Kakushadze, Z. 101 formulaic alphas. *Wilmott*, 2016(84): 72–81, July 2016.

Kim, M., Becker, Y. L., Fei, P., and O'Reilly, U. M. Constrained genetic programming to minimize overfitting in stock selection. In *Genetic Programming Theory and Practice VI, Genetic and Evolutionary Computation*, pp. 179–195, 2008.

Koza, J. R. *Genetic Programming: On the Programming of Computers by Means of Natural Selection*. MIT Press, 1992.

Li, C. and Liu, F. A multi-factor stock selection system based on short-term price and volume characteristics. Technical report, Guotai Junan, June 2017.

Lin, X. and Chen, Y. Stock selection factor mining based on genetic programming. Technical report, Huatai Securities, June 2019a.

Lin, X. and Chen, Y. Re-examining stock selection factor mining based on genetic programming. Technical report, Huatai Securities, August 2019b.

Lin, X. and He, K. Gpu acceleration for genetic programming factor mining. Technical report, Huatai Securities, February 2024.

Long, X., Kampouridis, M., and Jarchi, D. An in-depth investigation of genetic programming and nine other machine learning algorithms in a financial forecasting problem. In *2022 IEEE Congress on Evolutionary Computation (CEC)*, pp. 01–08. IEEE, July 2022.

Narang, R. K. *Inside the Black Box: A Simple Guide to Quantitative and High-Frequency Trading*, volume 846. John Wiley & Sons, 2013.

O'Neill, M., Vanneschi, L., Gustafson, S., and Banzhaf, W. Open issues in genetic programming. *Genetic Programming and Evolvable Machines*, 11:339–363, 2010.

Sharpe, W. F. Capital asset prices: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, 19(3):425–442, 1964.

Soule, T. and Heckendorn, R. B. An analysis of the causes of code growth in genetic programming. *Genetic Programming and Evolvable Machines*, 3:283–309, 2002.

Xia, Y., Tian, S. P., Wei, H. Y., and Wang, Z. W. Research on symbolic regression based on genetic programming. *Journal of China Jiliang University*, 17(2):128–131, 2006.

Zhang, H. Genetic programming deconstruction and investment insights. Technical report, Guotai Junan, August 2023.

Zhang, T., Li, Y., Jin, Y., and Li, J. Autoalpha: An efficient hierarchical evolutionary algorithm for mining alpha factors in quantitative investment. *arXiv preprint arXiv:2002.08245*, 2020.

Zhaofan, S., Jianwu, L., and Chengshan, Z. Genetic algorithm based quantitative factors construction. In *2022 IEEE 20th International Conference on Industrial Informatics (INDIN)*, pp. 650–655. IEEE, 2022.

毕业论文（设计）文献综述和开题报告考核

对文献综述、外文翻译和开题报告评语及成绩评定：

成绩比例	文献综述 占（10%）	开题报告 占（15%）	外文翻译 占（5%）
分值			

开题报告答辩小组负责人（签名）_____

年　月　日